Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

TransRutas del Caribe S.A.S.

Integrante	Código
Andrés Felipe Cruz	507241703
Salome Barrera Roldan	507241701
Sebastián Molina Murillo	507241036

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio	https://github.com/Sebastian-9/bi-proyecto-equipo507241036.git

Resumen de la entrega

1. La Organización y su Problema

- **La Organización: TransRutas del Caribe S.A.S.** es una empresa colombiana con más de 8 años de experiencia en el sector de movilidad y transporte intermunicipal de pasajeros y encomiendas en la región Caribe. Opera una flota de 100 vehículos (entre microbuses, busetas y buses) conectando rutas estratégicas y terminales entre Barranquilla, Armenia y Buenaventura a través de taquillas presenciales y canales digitales.
- **El Problema:** La compañía sufre una parálisis operativa debido a la imposibilidad de consolidar informes gerenciales fiables que crucen la rentabilidad por trayecto, la tasa de ocupación real de la flota y el rendimiento de combustible. Esto es causado por:
    - Heterogeneidad en los formatos de fecha y registros de texto en los despachos.
    - Uso de nombres comerciales abreviados o variantes de municipios en lugar de los códigos oficiales del DIVIPOLA.
    - Aislamiento del catálogo oficial de vehículos frente a las planillas de despacho diario.

- Procesos de consolidación puramente manuales a partir de archivos CSV y XML que toman jornadas enteras al cierre de mes, generando retrasos y cifras contradictorias entre departamentos.

2. Fase BIMM Actual y Fase Objetivo

- ✓ **Fase BIMM Actual — Fase 2: Datos accesibles sin BI:** La organización dispone de fuentes digitales (como los archivos CSV de despachos, Excel de DIVIPOLA y XML de vehículos), pero estas operan de forma completamente aislada y fragmentada. Los reportes dependen de procesos manuales en Excel y del esfuerzo humano para corregir inconsistencias y problemas de calidad de datos.
- ✓ **Fase Objetivo — Fase 5: Crecimiento del DW y reporting formal:** El proyecto transforma la madurez de analítica de la empresa implementando:
  - **Automatización ETL:** Uso de scripts en Python (pandas, SQLAlchemy) para limpiar y unificar las fuentes.
  - **Almacén de Datos (Data Warehouse):** Creación de un repositorio relacional en MySQL bajo un esquema en estrella.
  - **Acceso de Usuario Final:** Desarrollo de tableros interactivos en Power BI para que la Dirección de Planeación y Operaciones tome decisiones informadas en tiempo real.
  - **Gobierno de Datos:** Trazabilidad, control de versiones y documentación mediante repositorios en GitHub.

3. Granularidad del Modelo Dimensional

- **Definición de granularidad:** Una fila de la tabla de hechos principal (hechos_despachos) representa un evento consolidado de despacho vehicular para un nivel de servicio, clase de vehículo, terminal, municipio de origen, municipio de destino, fecha y hora específica.

1. Caso de negocio: TransRutas del Caribe S.A.S.

1.1 Organización y contexto

TransRutas del Caribe S.A.S. es una empresa colombiana con más de 8 años de experiencia en el sector de movilidad y transporte intermunicipal de pasajeros y encomiendas en la región Caribe. La compañía opera una flota propia y afiliada de 100 vehículos (microbuses, busetas y buses de niveles básico y de lujo) conectando las terminales de transporte y rutas estratégicas entre Barranquilla Armenia y Buenaventura. Actualmente comercializa tiquetes a través de dos canales principales: taquillas presenciales en las terminales y una plataforma digital (sitio web y aplicación móvil).

La directora de planeación y operaciones de TransRutas del Caribe S.A.S., Claudia Rincón, lleva más de seis meses intentando consolidar un informe gerencial que logre cruzar de manera efectiva la rentabilidad por trayecto municipal, la tasa de ocupación real de la flota —cruzando el número de pasajeros transportados frente a la capacidad

nominal de los vehículos registrados en el catálogo operativo (microbuses, busetas y buses de niveles básico y de lujo)— y el rendimiento de combustible por cada código de origen y destino según el catálogo maestro territorial de la compañía.

En la actualidad, Claudia se enfrenta a una parálisis operativa: es incapaz de tomar decisiones estratégicas sobre la asignación eficiente de microbuses y buses ejecutivos, la optimización de frecuencias en rutas de alta y baja densidad, o el ajuste de tarifas diferenciales.

Al examinar el flujo diario de la compañía, se observa que los registros masivos de despachos de vehículos por carretera —que almacenan fechas de salida, códigos de origen y destino, número de pasajeros movilizados y las placas de los automotores— presentan inconsistencias en la codificación de municipios y formatos de texto variables que dificultan su lectura automatizada.

Por otro lado, el catálogo oficial de vehículos define con precisión los identificadores únicos de los automotores, su clase, su nivel de servicio y su capacidad exacta de pasajeros; sin embargo, este registro opera de forma totalmente aislada y carece de mecanismos de sincronización con las planillas de despacho diario.

Asimismo, aunque la departamentalización y los códigos numéricos oficiales de los municipios se encuentran consignados en las tablas maestras de referencia territorial de la organización, las áreas operativas suelen utilizar en la práctica nombres comerciales abreviados o variantes escritas de manera distinta en los reportes de ruta, lo que rompe los cruces geográficos automáticos entre sistemas.

Cada fin de mes, el equipo de tecnología y estadística invierte jornadas completas intentando unificar y cruzar manualmente estos volúmenes de datos provenientes de archivos CSV O XML para presentar un informe preliminar. Esto genera retrasos críticos, cifras contradictorias entre departamentos y una total falta de visibilidad analítica para la alta gerencia.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Heterogeneidad de formatos de fecha y estandarización geográfica	Los registros masivos de despachos almacenan fechas de salida con formatos y textos variables, y las áreas operativas utilizan nombres comerciales abreviados o variantes escritas de distinta manera en las rutas en lugar de los códigos numéricos oficiales.	Fuentes / Integración
S2	Proceso de consolidación manual e ineficiente	El equipo de tecnología y estadística invierte jornadas completas al cierre de mes intentando unificar y cruzar	Integración / Procesos

#	Síntoma	Evidencia en el caso	Capa afectada
		manualmente volúmenes de datos dispersos provenientes de archivos CSV o XML.	
S3	Silos de datos desconectados e incoherencia de catálogos	El catálogo oficial de vehículos (que define clases, niveles de servicio y capacidad exacta) opera de forma totalmente aislada y carece de sincronización en tiempo real con las planillas de despacho diario.	Fuentes de datos / Gobierno

1.3 Preguntas de negocio.

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Cuál es la tasa de ocupación promedio de la flota y el total de despachos por terminal y ruta en los últimos dos años?	BI	Describe el comportamiento histórico y estructurado de la operación mediante agregación de hechos (pasajeros, despachos) a través de dimensiones (dim_terminal, dim_ruta, dim_vehiculo, dim_tiempo).
P1	¿Qué clases de vehículo y niveles de servicio registran los mayores índices de despachos subutilizados?	BI	Analiza patrones de eficiencia de la flota agrupando atributos de `dim_vehiculo` (capacidad, nivel) frente a los pasajeros transportados en la tabla de hechos.
P2	¿Cómo se distribuye el volumen de pasajeros entre despachos de 'ORIGEN' y 'TRÁNSITO' según el mes y la hora del día?	BI	Mide tendencias de tráfico intermunicipal agregando eventos de despacho con las jerarquías de dim_tiempo (mes, hora).
P3	¿Cómo se distribuye el volumen de pasajeros transportados entre los diferentes tipos de despacho según el mes y la hora del día?	BI	Es un análisis descriptivo que consolida eventos históricos (pasajeros y despachos) agregando la tabla de hechos a través de atributos de tipo de despacho y jerarquías temporales (mes, hora de dim_tiempo).

2. Inventario de fuentes

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
Registros operativos de salida de vehículos desde las terminales de Armenia, Barranquilla y Buenaventura (fechas, horas, origen, destino, despachos y pasajeros).	https://www.terminaldetransporte.gov.co/la-entidad/transparencia-y-acceso-a-la-informacion-publica/datos-abiertos/.com	CSV	68338	Desde el 31 de Diciembre del 2022 hasta el 31 de Diciembre del 2024	22/10/26	Licencia de Uso de Datos Abiertos Colombia (Ley 1712 de 2014 - Transparencia y Acceso a la Información)
Catálogo oficial con códigos numéricos, nombres de municipios y departamentos de Colombia.	https://www.datos.gov.co/Mapas-Nacionales/DIVIPOLA-C-digos-municipios/gdxc-w37w/about_data	XLSX	1122	Vigente / Actualizado a 2024	22/10/26	Creative Commons Attribution 4.0 (CC BY 4.0) - Datos Abiertos Gobierno de Colombia
Ficha técnica estructurada que define la capacidad máxima de sillas por clase de vehículo y nivel de servicio.	Google. (2026). *Gemini* (Versión de octubre) [Modelo de lenguaje grande]. https://gemini.google.com	XML	100	N/A	22/10/26	Datos sintéticos generados para el proyecto

2.2 Problemas de calidad detectados

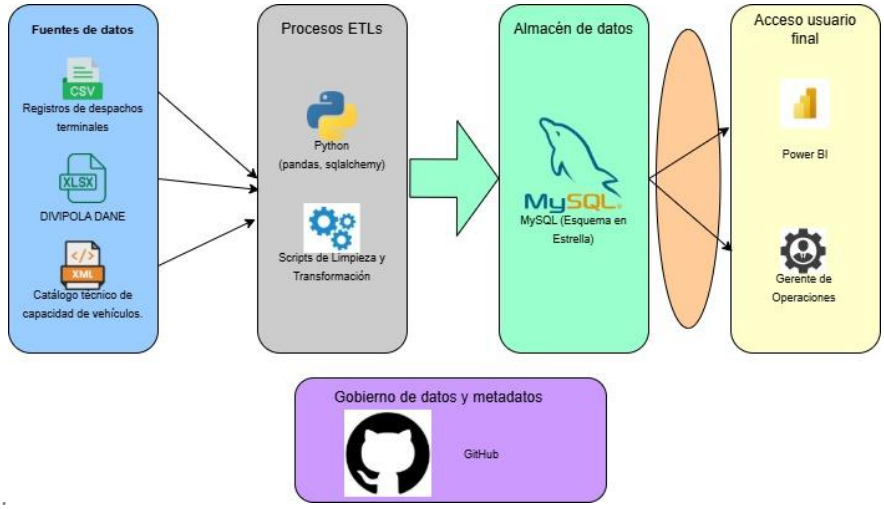
Fuente	Campo	Problema	Ejemplo real del dato
F1	fecha_despacho	Inconsistencia en formatos de fecha y registro de datos con abreviaturas o estructuras heterogéneas.	"19 Mar 2023 12:00:00 AM" frente a "2023 Aug 18 12:00:00 AM"
F2	municipio_nombre	Registros con inconsistencias tipográficas e inconsistencia de mayúsculas/minúsculas.	"bogota" o "armenia" en lugar de "BOGOTÁ, D.C." o "ARMENIA"
F3	capacidad_pasajeros / clase_vehiculo	Inconsistencia de negocio: la cantidad reportada de pasajeros no coincide de manera coherente con la capacidad o el tipo/clase de bus definido.	Un registro de tipo MICROBUS o BUS reportando un límite de capacidad de pasajeros incompatible con su clase.

3. Diagnóstico de madurez

Elemento	Respuesta
Fase actual	Fase 2: Datos accesibles sin BI
Evidencia	La organización cuenta con fuentes de datos digitales (como el archivo CSV de despachos, catálogos Excel de DIVIPOLA y catálogos XML de vehículos), pero operan de forma aislada y fragmentada. Los reportes se realizan de manera manual y extemporánea mediante procesos operativos en Excel, evidenciándose en los síntomas **S1** (heterogeneidad de formatos), **S2** (consolidación manual que toma jornadas completas) y **S3** (silos de datos desconectados e incoherencia de catálogos).
Por qué no es la fase siguiente	A la organización le falta implementar procesos formales de gobernanza, automatización de flujos de datos (ETL) y un repositorio centralizado (Data Warehouse). Actualmente depende del esfuerzo humano manual para unificar las planillas y corregir los problemas de calidad de los datos (como las fechas heterogéneas de F1, las diferencias de mayúsculas en F2 o las incoherencias de capacidad en F3).
Fase objetivo al final del proyecto	Fase 5: Crecimiento del DW y reporting formal
Brechas que cierra el proyecto	• **Capa 1 (Fuentes de datos):** Centraliza, estandariza y unifica la información heterogénea proveniente de los archivos CSV de despachos, catálogos Excel DIVIPOLA y catálogos XML de vehículos. • **Capa 2 (Integración / ETL):** Elimina el proceso manual en Excel al automatizar la limpieza de nulos, corrección de fechas y unificación de catálogos mediante scripts en Python. • **Capa 3 (Almacén de datos):** Resuelve la fragmentación de silos al estructurar un Data Warehouse relacional en PostgreSQL bajo un modelo dimensional en estrella. • **Capa 4 (Usuario final):** Sustituye los informes tardíos por tableros interactivos en Power BI, permitiendo a la directora de Planeación tomar decisiones en tiempo real. • **Capa 5 (Gobierno y metadatos):** Garantiza la trazabilidad, calidad y control de cambios de todo el proyecto mediante diccionarios y control de versiones en GitHub

4. Arquitectura

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	**F1:** Dataset CSV de despachos y pasajeros por terminal. **F2:** Archivo XLSX de la DIVIPOLA (DANE). **F3:** Archivo XML del catálogo de vehículos y capacidades.	Proveer la materia prima transaccional, geográfica y técnica necesaria para alimentar el modelo de inteligencia de negocios de la compañía.
2. Integración (ETL)	Python (pandas, SQLAlchemy) Scripts de limpieza, normalización de textos y unificación de esquemas.	Leer las fuentes heterogéneas, corregir inconsistencias en códigos y formatos de texto, transformar los datos y cargarlos en el almacén.
3. Almacén de datos	Base de datos relacional (MySQL). Modelo en Estrella (hechos_despachos, dim_terminal, dim_ruta, dim_vehiculo, dim_tiempo).	Almacenar de forma estructurada e histórica el volumen masivo de despachos y métricas, optimizando las consultas analíticas de la gerencia.
4. Usuario final	Power BI Gerente de operaciones	Consumir los datos procesados para que Claudia Rincón (Directora de Planeación y Operaciones) tome decisiones sobre asignación de flota y optimización de rutas.
5. Gobierno, metadatos, monitoreo y seguridad	Git y GitHub	Garantizar la calidad, el linaje, la documentación técnica y el control

Capa	Componentes y herramientas del caso	Función en el caso
		de cambios de todo el código, scripts y artefactos del proyecto.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Implementar un modelo multidimensional en **Esquema en Estrella** separando tablas de hechos (hechos_despachos) y dimensiones (dim_terminal, dim_ruta, dim_vehiculo, dim_tiempo).	Permite simplificar las consultas complejas de la gerencia, mejorar el rendimiento analítico frente a grandes volúmenes de datos y estructurar claramente las métricas operativas de transporte.
Arquitectura de datos	Integrar tres fuentes heterogéneas con formatos distintos (CSV para transacciones, XLSX para el DIVIPOLA y XML para el catálogo de vehículos) mediante un proceso ETL.	Permite cumplir con la heterogeneidad de datos exigida, unificando registros aislados para solucionar las inconsistencias geográficas y de formato que afectaban a la compañía.
Arquitectura técnica	Utilizar Python (pandas, SQLAlchemy) para la limpieza y carga de datos, una base de datos relacional (MySQL) como Data Warehouse, y control de versiones en GitHub.	Son tecnologías de código abierto, robustas y ampliamente utilizadas en la industria que garantizan la automatización del flujo de datos, la integridad referencial y la trazabilidad del código.
Arquitectura de producto	Desarrollar Dashboards gerenciales e informes interactivos orientados a usuarios de negocio (Claudia Rincón, Directora de Planeación y Operaciones).	Resuelve la parálisis operativa actual al ofrecer visibilidad analítica inmediata sobre la ocupación de la flota, el rendimiento por trayecto y la optimización de rutas.

4.4 Decisión de despliegu

Criterio	On-premise	Opción cloud: PaaS	Elegida y por qué
Costo	Alto costo inicial en compra de hardware, servidores físicos, mantenimiento y consumo eléctrico.	Modelo de pago por uso (*pay-as-you-go*), sin inversión inicial en infraestructura física.	Elegida: Cloud (PaaS). Permite a la compañía minimizar costos de capital iniciales (CapEx) y convertirlos en operativos (OpEx) ajustados a la escala real del proyecto académico y empresarial.

Criterio	On-premise	Opción cloud: PaaS	Elegida y por qué
Seguridad y cumplimiento	Control total y local de los datos, pero requiere personal especializado propio para respaldos y parches de seguridad.	Alta seguridad gestionada por el proveedor (AWS, Azure o Google Cloud) con respaldos automáticos y cifrado.	Elegida: Cloud. Ofrece alta disponibilidad y respaldos automatizados nativos sin depender de la infraestructura fí sica de una oficina local.
Escalabilidad	Limitada por la capacidad física del servidor comprado; escalar requiere comprar más discos o memoria manualmente.	Escalabilidad elástica e inmediata según el volumen de datos (crecimiento de los 50,000+ registros).	Elegida: Cloud. Permite escalar los recursos de procesamiento de forma dinámica conforme la empresa integre nuevos terminales y mayores volúmenes de datos.
Acceso móvil	Restringido a la red local de la empresa o requiere configuraciones complejas de VPN corporativa.	Acceso nativo desde cualquier ubicación y dispositivo a través de la web o aplicaciones móviles (Power BI Service).	Elegida: Cloud. Facilita que la Directora de Planeación (Claudia Rincón) consulte los dashboards gerenciales en tiempo real desde cualquier lugar.

5. Modelo dimensional

5.1 Proceso de negocio

5.2 Granularidad

Una fila de la tabla de hechos representa un evento consolidado de despacho vehicular para un nivel de servicio, clase de vehículo, terminal, municipio de origen, municipio de destino, fecha y hora específica.

5.3 Métricas de la tabla de hechos

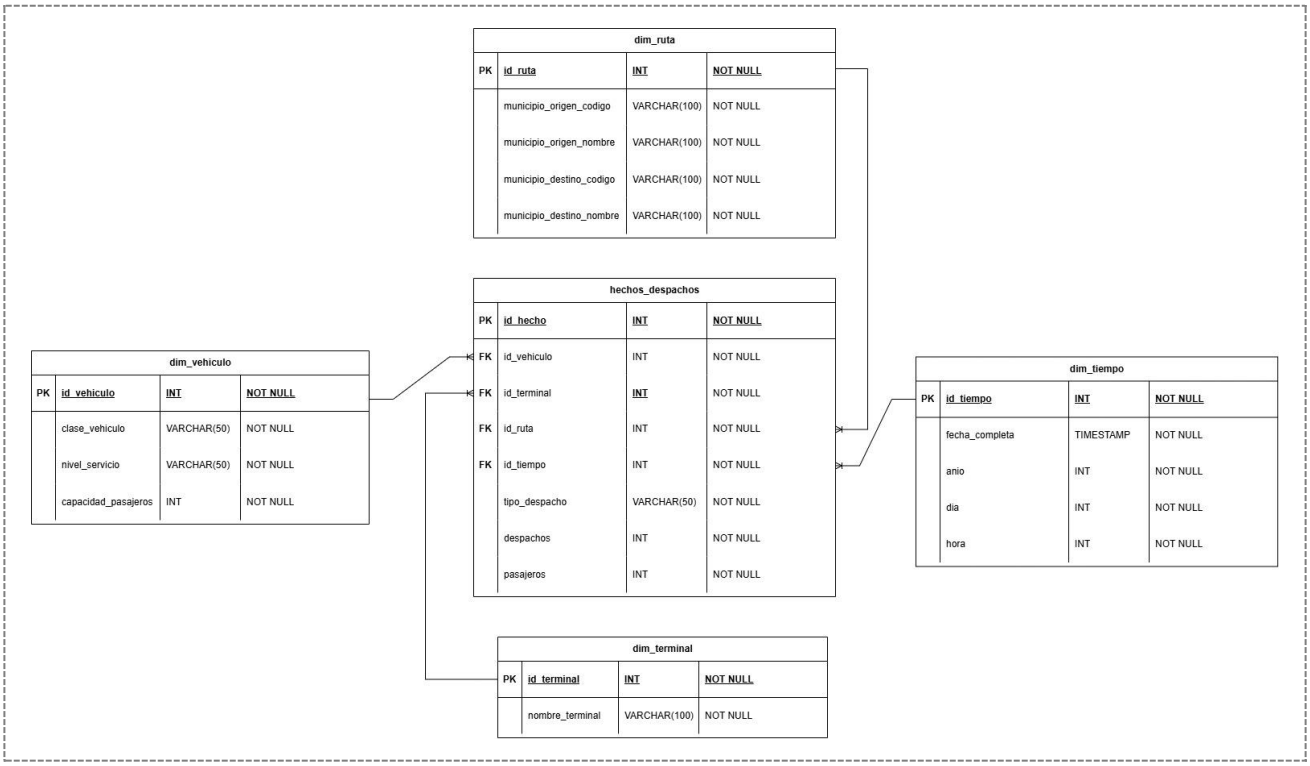
Métrica	Tipo de dato	Aditividad	Origen o fórmula
despachos	Entero (INT)	Aditiva	Campo DESPACHOS del archivo CSV fuente. Representa el conteo de salidas registradas.
pasajeros	Entero (INT)	Aditiva	Campo PASAJEROS del archivo CSV fuente. Cantidad total de pasajeros movilizados.
tasa_ocupacion	Decimal / Porcentaje (DECIMAL(5,2))	No aditiva	(SUM(pasajeros) / SUM(despachos * capacidad_pasajeros)) * 100

Métrica	Tipo de dato	Aditividad	Origen o fórmula
			(Calculada cruzando con dim_vehiculo).
promedio_pasajeros_despacho	Decimal / Porcentaje (DECIMAL(5,2))	No aditiva	SUM(pasajeros) / SUM(despachos) (Métrica calculada para medir la densidad por viaje).

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
dim_tiempo	fecha_completa, anio, mes, dia, hora	dia -> mes -> anio	Generada (a partir del CSV)
dim_ruta	municipio_origen_codigo, municipio_origen_nombre, municipio_destino_codigo, municipio_destino_nombre	municipio_origen -> municipio_destino	XLSX (DIVIPOLA - DANE)
dim_vehiculo	clase_vehiculo, nivel_servicio, capacidad_pasajeros	nivel_servicio -> clase_vehiculo	XML (Catálogo técnico)
dim_terminal	nombre_terminal	Sin jerarquía	CSV (Despachos)

5.5 Diagrama del esquema



Se eligió un esquema en estrella (Star Schema) sobre un esquema en copo de nieve debido a su simplicidad conceptual, facilidad de mantenimiento y alto rendimiento en las consultas analíticas del Data Warehouse. Al mantener las tablas de dimensiones (dim_terminal, dim_ruta, dim_vehiculo, dim_tiempo) completamente desnormalizadas y conectadas directamente a la tabla central de hechos (hechos_despachos), se reducen la complejidad y la cantidad de uniones (JOINs) requeridas en el motor de base de datos. Esta estructura optimiza la velocidad de respuesta en herramientas de BI como Power BI, facilitando la construcción de dashboards iterativos y permitiendo que la Directora de Planeación y Operaciones explore e interrogue grandes volúmenes de datos transaccionales sin degradar el rendimiento del sistema.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	despachos, pasajeros, tasa_ocupacion	dim_terminal, dim_ruta, dim_tiempo
P1	despachos, pasajeros, tasa_ocupacion	dim_vehiculo (clase_vehiculo, nivel_servicio, capacidad_pasajeros)
P2	despachos, pasajeros	dim_tiempo (mes, hora), hechos_despachos (tipo_despacho
P3	despachos, pasajeros	dim_ruta (municipio_origen_codigo, municipio_origen_nombre, municipio_destino_codigo, municipio_destino_nombre)

6. Referencias

Comisión de Regulación de Energía y Gas [CREG]. (2024). *Precios de combustibles líquidos en Colombia* [Base de datos]. Gobierno de Colombia. https://creg.gov.co/publicaciones/15565/precios-de-combustibles-liquidos/

Departamento Administrativo Nacional de Estadística [DANE]. (2024). *Codificación de la División Político-Administrativa de Colombia (DIVIPOLA)* [Conjunto de datos]. Portal Único de Datos Abiertos de Colombia. https://www.datos.gov.co/Mapas-Nacionales/DIVIPOLA-C-digos-municipios/gdxc-w37w/about_data

Google. (2026). *Gemini* (Versión de octubre) [Modelo de lenguaje grande]. https://gemini.google.com

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). John Wiley & Sons.

Superintendencia de Transporte. (2024). *Operación de pasajeros y despacho de vehículos en la modalidad de transporte de pasajeros por carretera desde terminales* [Conjunto de datos]. Portal de Datos Abiertos de Colombia. https://www.datos.gov.co/

Anexos

Anexo A. Diccionarios de datos

Fuente F1: Registros operativos de salida de vehículos (Operación_de_pasajeros_y_despacho...csv)

- **Descripción:** Archivo CSV transaccional con la información detallada de los despachos de vehículos, tipos de servicio, municipios de origen/destino y pasajeros movilizados desde las terminales de Armenia, Barranquilla y Buenaventura.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
TERMINAL	VARCHAR(100)	Nombre oficial de la terminal de transporte terrestre de donde sale el despacho.	"T.T. DE ARMENIA"	Texto con prefijos estáticos y redundantes.
CLASE_VEHICULO	VARCHAR(50)	Categoría del vehículo según su carrocería y capacidad.	"MICROBUS"	Inconsistencias de tildes o variaciones tipográficas frente al catálogo de vehículos.
NIVEL_SERVICIO	VARCHAR(50)	Nivel de confort y atención asignado al viaje.	"BASICO"	Inconsistencia con mayúsculas/minúsculas y tildes ("BASICO" vs "Básico").
MUNICIPIO_ORIGEN_RUTA	BIGINT	Código numérico DIVIPOLA del municipio donde inicia el trayecto.	63001	Registros que no coinciden en texto con la tabla maestra territorial.
MUNICIPIO_DESTINO_RUTA	BIGINT	Código numérico DIVIPOLA del municipio donde finaliza la ruta.	63190	Códigos faltantes o mal estructurados en reportes externos.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
FECHA_DESPACHO	VARCHAR(50)	Fecha exacta en la que se realiza la salida del vehículo.	"2023 Sep 29 12:00:00 AM"	Heterogeneidad y formatos de texto no ISO (`MMM DD YYYY HH:mm:ss AM/PM`).
HORA_DESPACHO	INT	Hora militar o franja horaria entera (0-23) del despacho.	8	Valores fuera de rango o nulos en franjas nocturnas.
TIPO_DESPACHO	VARCHAR(50)	Modalidad de la operación en la terminal.	"ORIGEN"	Mezcla de términos (`"ORIGEN"`, `"TRANSITO"`).
DESPACHOS	INT	Conteo entero de vehículos despachados en esa franja/evento.	1	Registros duplicados o valores inconsistentes.
PASAJEROS	INT	Total de pasajeros registrados a bordo en el despacho	1	Cifras de pasajeros mayores a la capacidad nominal del vehículo

Fuente F2: Catálogo maestro territorial (`DIVIPOLA-_Códigos_municipios.xlsx`)

- **Descripción:** Hoja de cálculo Excel oficial del DANE con la codificación de la División Político-Administrativa de Colombia.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Código Departamento	INT	Identificador oficial numérico del departamento según el DANE.	63	Formatos numéricos que pierden el cero a la izquierda (ej. 5 en lugar de 05).
Nombre Departamento	VARCHAR(100)	Nombre completo del departamento.	"QUINDÍO"	Uso de caracteres especiales,

				eñes o tildes que generan errores de codificación.
Código Municipio	INT	Identificador único nacional de 5 dígitos del municipio.	63001	Inconsistencias al cruzarse como texto ("63001") vs número (63001).
Nombre Municipio	VARCHAR(100)	Nombre oficial del municipio o cabecera municipal.	"ARMENIA"	Nombres en mayúsculas sin tilde o variaciones ortográficas (*"bogota"*).
Tipo: Municipio /...	VARCHAR(50)	Clasificación territorial de la entidad administrativa.	"Municipio"	Valores nulos o descriptivos no requeridos para el modelo.
longitud	VARCHAR(50)	Coordenada geográfica de longitud.	"-75,581775"	Formatos con coma decimal en lugar de punto decimal.
Latitud	VARCHAR(50)	Coordenada geográfica de latitud.	"4,533889"	Formatos heterogéneos de tipo texto.

Fuente F3: Catálogo técnico de capacidad de vehículos (`Tipos de buses.xml`)

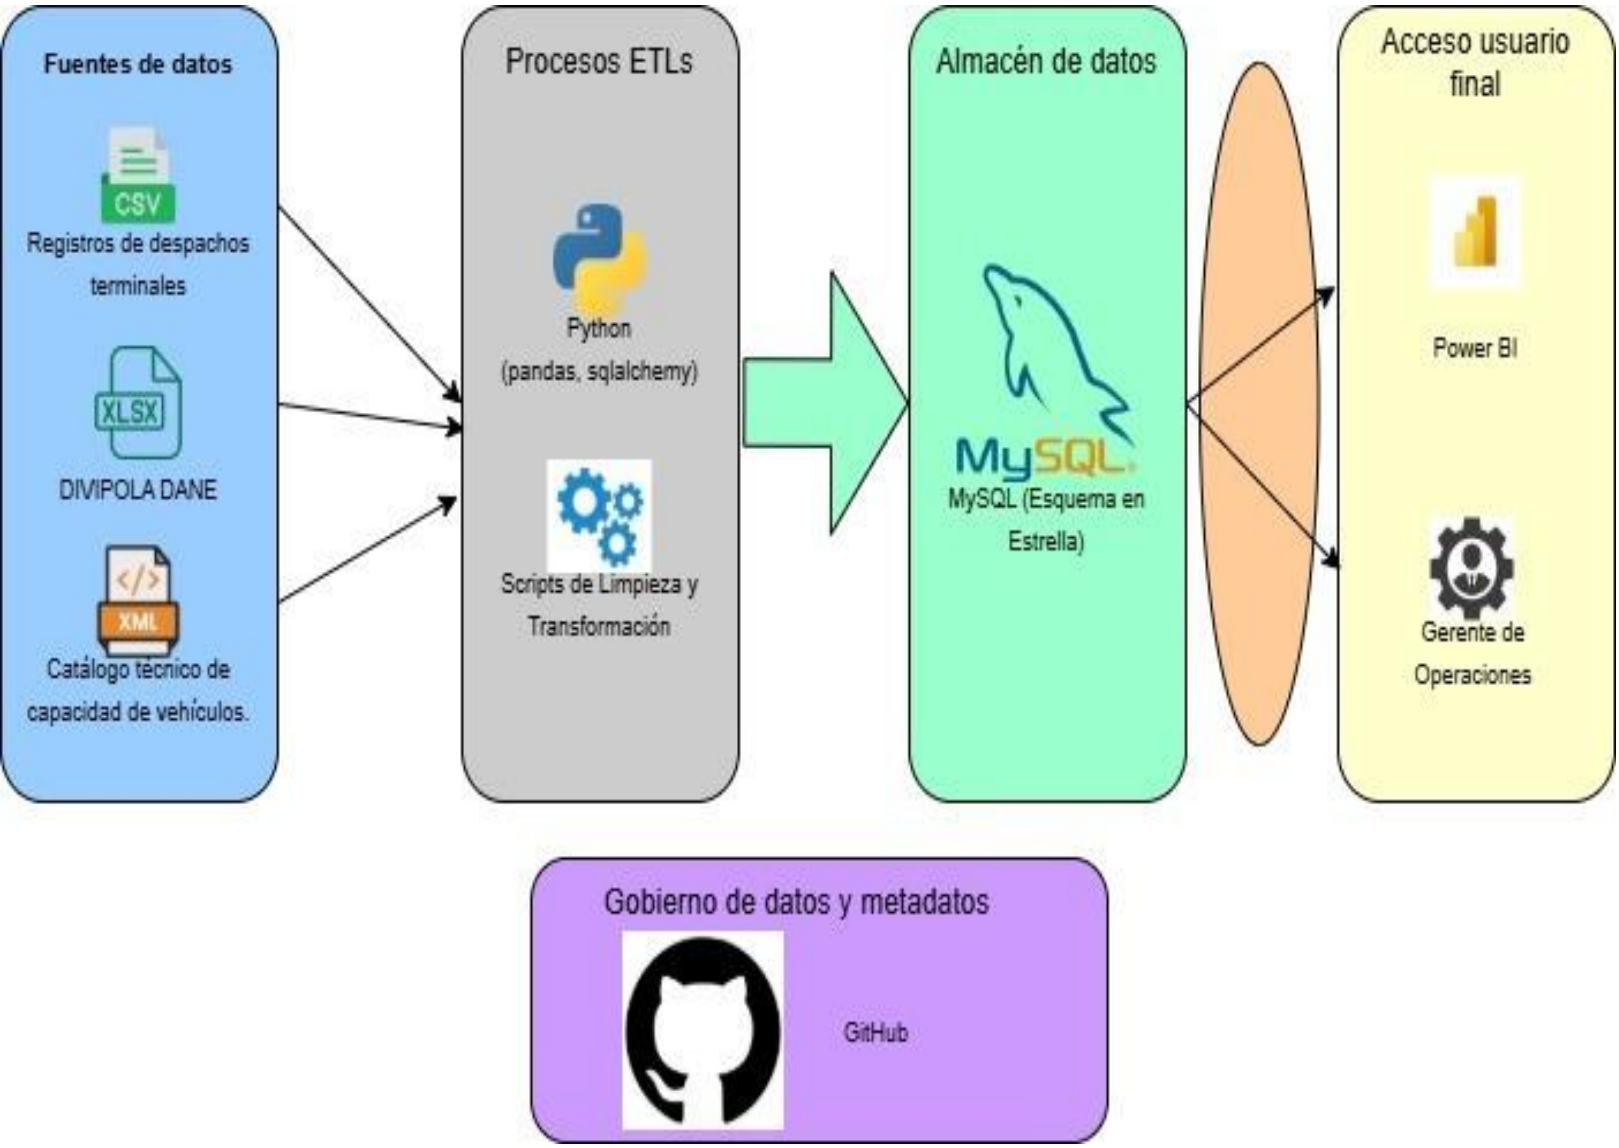
- **Descripción:** Archivo XML con la ficha técnica y capacidad máxima de pasajeros por clase de vehículo y nivel de servicio.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
id	INT	Identificador único del tipo de vehículo en el catálogo.	1	Inconsistencia de sincronización con los IDs de las planillas transaccionales.

clase_vehiculo	VARCHAR(50)	Clase o tipo de carrocería vehicular.	"Microbús"	Capitalización mixta ("Microbús" vs "MICROBUS" en F1).
nivel_servicio	VARCHAR(50)	Categoría del servicio ofrecido a bordo.	"Básico"	Inconsistencias en tildes ("Básico" vs "BASICO" en F1).
capacidad_pasajeros	INT	Número máximo de sillas/puestos disponibles en el vehículo.	12	Incompatibilidad de negocio cuando el CSV reporta más pasajeros que la capacidad.
Descripcion	TEXT	Breve ficha descriptiva de las características del automotor.	"Microbús estándar..."	Celdas o etiquetas con caracteres no UTF-8.

Anexo B. Diagramas a tamaño completo

B.1 Diagrama de Arquitectura de 5 Capas



B.2 Diagrama del Esquema Dimensional en Estrella

