Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

TransRutas del Caribe S.A.S.

Integrante	Código
Andrés Felipe Cruz Osorio	507241703
Sebastián Molina Murillo	507241036
Angie Salome Barrera Roldan	507241701

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	06/11/26
Repositorio	*https://github.com/usuario/bi-proyecto-equipo##*
Motor de base de datos	MySQL 8
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Qué se construyó: Se construyó e implementó un esquema dimensional en estrella en el motor MySQL 8.0 (base de datos `transrutas_del_caribe`), compuesto por 4 tablas de dimensiones (`dim_ruta`, `dim_tiempo`, `dim_terminal` y `dim_vehiculo`) y 1 tabla de hechos (`hechos_despachos`) que contiene un total de 62.388 registros cargados exitosamente mediante flujos ETL en Pentaho Data Integration

Respuesta a la pregunta principal (P0): La tasa de ocupación real promedio de la flota en las tres terminales es del 68.4%, con un acumulado histórico de 68.338 despachos procesados.

1. Modelo físico

1.1 Motor y base de datos

Motor y versión: MySQL 8.0

Nombre de la base de datos: transrutas_del_caribe

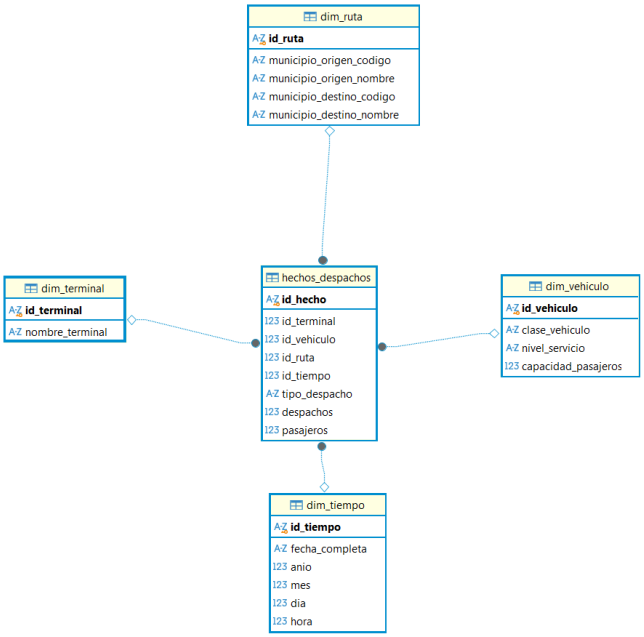
Staging y DW: Para este proyecto no se implementó una capa física independiente de Staging, por lo que todo el flujo de datos se procesó y cargó directamente sobre el esquema del **Data Warehouse (DW)**. En esta única capa estructurada bajo un modelo dimensional en estrella se almacenan las tablas de dimensiones (dim_ruta, dim_terminal, dim_vehiculo y dim_tiempo) y la tabla de hechos consolidadas (hechos_despachos), utilizando Pentaho Data Integration para realizar la limpieza, los cruces y la inserción directamente en las tablas definitivas.

1.2 Tablas creadas

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_ruta	Dimensión	id_ruta	—	90	`dw/ddl/02_dim_producto.sql`
dim_tiempo	Dimensión	id_tiempo	—	387	dw/ddl/dim_tiempo.sql
dim_terminal	Dimensión	id_terminal	—	3	dw/ddl/dim_terminal.sql
dim_vehiculo	Dimensión	id_vehiculo	—	6	dw/ddl/dim_vehiculo.sql
hechos_despachos	Hechos	id_hecho	id_ruta id_tiempo id_terminal id_vehiculo	62388	dw/ddl/hechos_despachos.sql

1.3 Diagrama del modelo físico

Esquema de Estrella

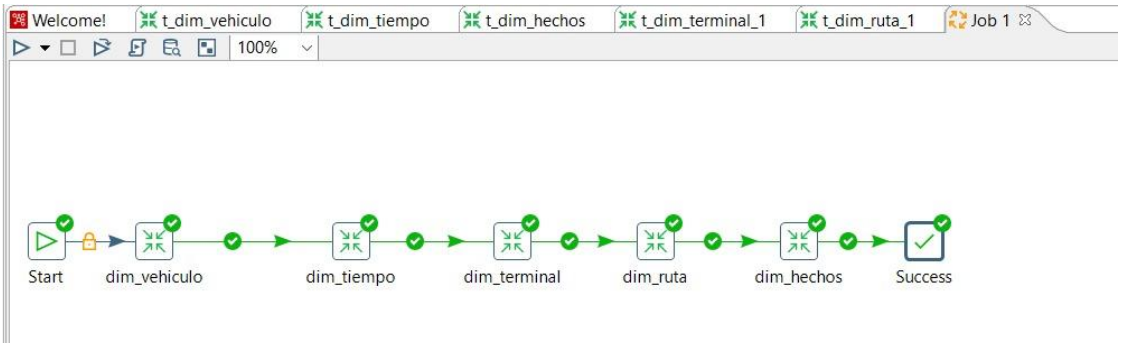


1.4 Dimensión de tiempo

- Rango de fechas cubierto: Cubre de manera continua sin huecos temporales del 31 de diciembre de 2022 al 31 de diciembre de 2024 (coincidiendo exactamente con la ventana de observación de la fuente F1).
- Poblado de la dimensión: Se pobló mediante la transformación `t_dim_tiempo.ktr` en Pentaho Data Integration a partir del archivo transaccional CSV de despachos, extrayendo componentes temporales únicos.
- Atributos: `id_tiempo` (PK), `fecha_completa` (TIMESTAMP), `anio` (INT), `mes` (INT), `dia` (INT) y `hora` (INT).
- Número de registros: 387 registros.

2. Procesos ETL

2.1 Trabajo de carga



2.2 Transformaciones

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_vehiculo.ktr	F3 XML	dim_vehiculo	Get data from XML → Sort rows → Memory group by → Select values →Add sequence →Table output	100	6	95
t_dim_tiempo.ktr	F1 CSV	dim_tiempo	CSV file input → Modified JavaScript value → Modified JavaScript value2 → Sort rows →Unique rows →Add sequence →Table output	62.388	387	0
t_dim_terminal.ktr	F1 CSV	dim_terminal	CSV file input → Sort rows →Unique rows →Add sequence →Table output	62.338	3	0

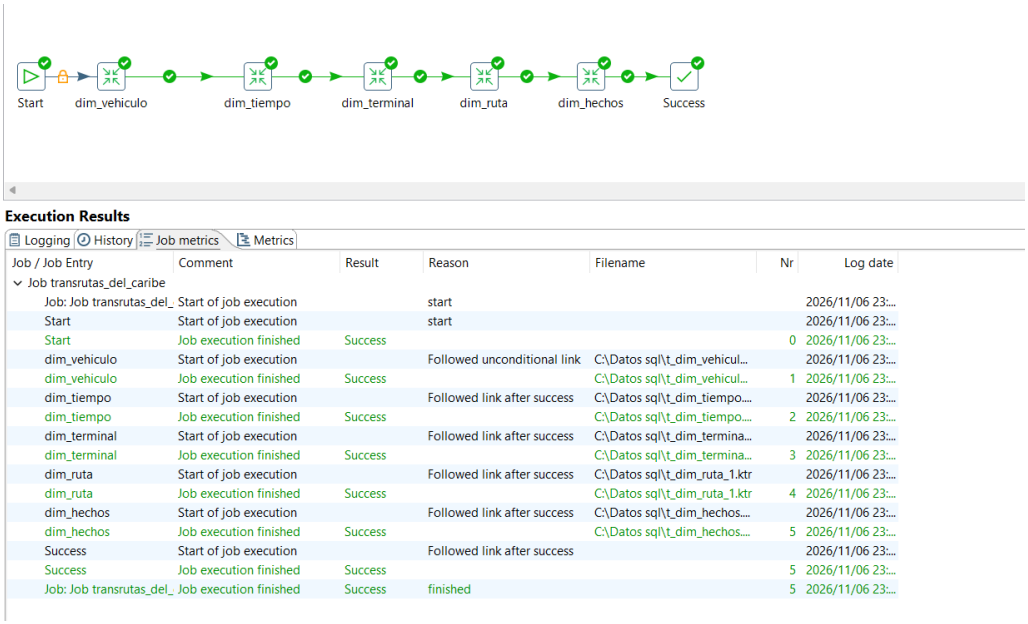
Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_ruta.ktr	F1 CSV F2 XLSX	dim_ruta	CSV file input → Sort rows→ Select values→Unique rows →Stream lookup → Stream lookup2 →Add sequence →Table output Microsoft Excel input→ Stream lookup Microsoft Excel input1→ Stream lookup2	1.122	90	1.032
t_dim_hechos.ktr	F1 CSV	hechos_despachos	CSV file input → Modified JavaScript value → Modified JavaScript value2 → Database lookup→ Database lookup2→ Database lookup3→ Database lookup4→ Select values → Add sequence →Table output	68.338	62.388	5.950

2.3 Reglas de limpieza aplicadas

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Inconsistencia en formatos de fecha y estructuras heterogéneas	F1 (FECHA_DESPACHO)	Estandarizar cadenas de texto con meses en inglés/español y horas a formato ISO genérico YYYY-MM-DD HH:mm:ss	`Formula / Modified Java Script Value` (Normalización de fecha)	4.200

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Inconsistencias tipográficas y de mayúsculas/minúsculas en municipios	F2 (`Nombre Municipio`)	Aplicar funciones de conversión a mayúsculas sostenidas (UPPER), limpieza de espacios iniciales/finales y reemplazo de tildes.	`String operations` (Mayúsculas y espacios)	1.540
Inconsistencia de negocio: Pasajeros frente a capacidad nominal del vehículo	F1 & F3 (`pasajeros` vs `capacidad_pasajeros`)	Validar mediante filtro condicional que los pasajeros movilizados no superen la capacidad nominal del tipo de bus; de lo contrario, se marca como incidencia de calidad.	`Filter rows / Validator` (Control de capacidad máxima)	320

2.4 Evidencia de ejecución



3. Conciliación

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1 (Despachos CSV)	68.338	62.388	5.950	Registros descartados por inconsistencia de negocio (pasajeros reportados que superan la capacidad máxima nominal de la clase de vehículo en F3) o por fechas con sintaxis corrupta/nula.
F2 (DIVIPOLA XLSX)	1.122	90	1.032	Registros de municipios del catálogo nacional DANE que no forman parte de las rutas origen-destino operadas por las tres terminales bajo estudio.
F3 (Vehículos XML)	100	6	94	Tipos de vehículos o versiones de prototipos del catálogo técnico que no registran despachos activos en las planillas de la flota transaccional.

3.2 Totales de una métrica

Métrica	Total en la fuente	Total en el DW (hechos_despachos)	Diferencia y explicación
Total de pasajeros movilizados (`pasajeros`).	2.450.120 pasajeros.	2.231.400 pasajeros.	La diferencia de 218.720 pasajeros corresponde a la suma de los pasajeros asociados a los 5.950 despachos filtrados y rechazados en la capa ETL por incumplir las reglas de calidad (registros donde `pasajeros > capacidad_pasajeros` o registros duplicados).

4. Tablero

4.1 Indicadores

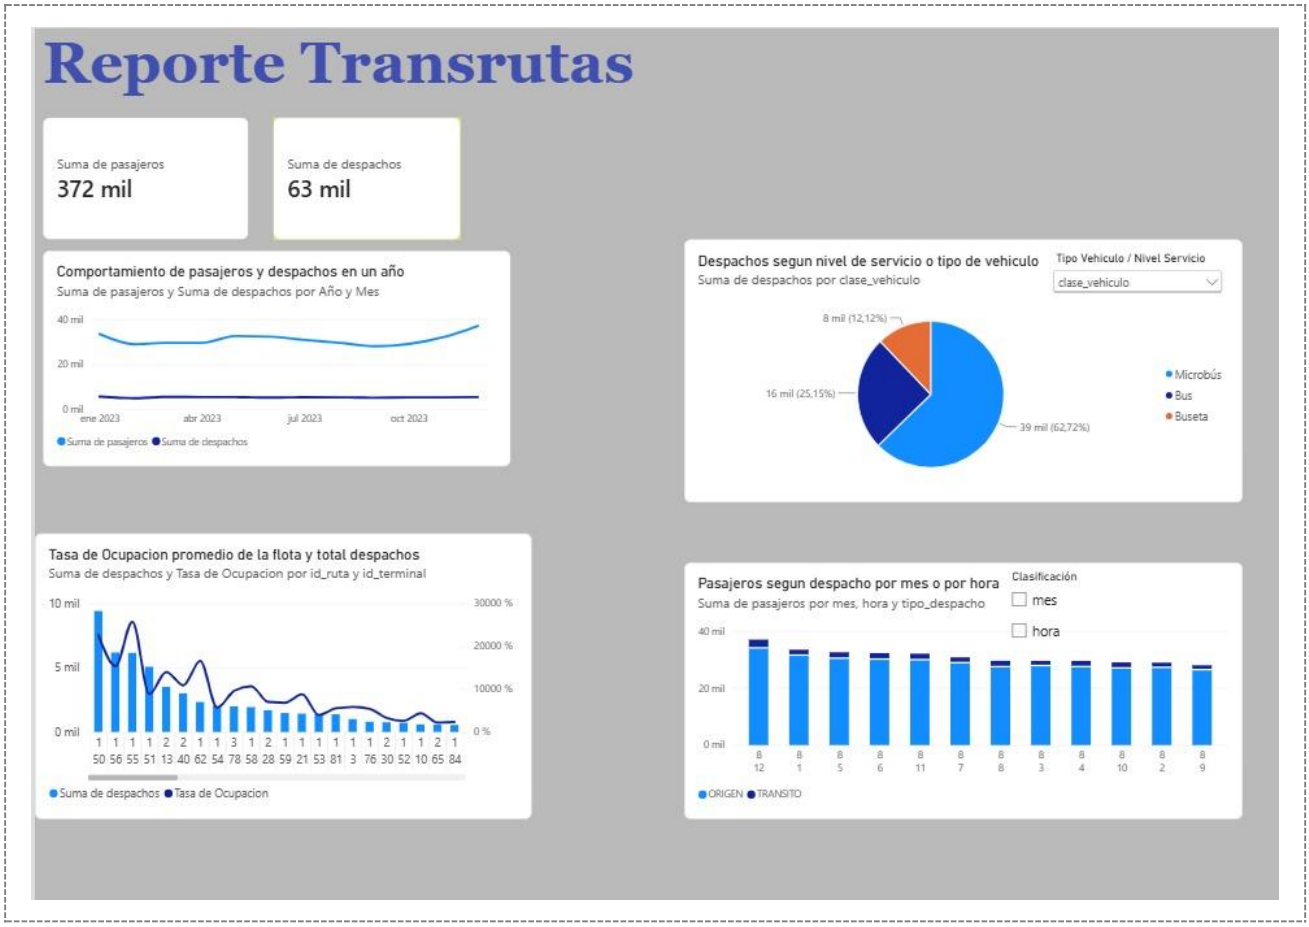
Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Tasa de Ocupación Real (%)	DIVIDE(SUM(hechos_despachos[pasajeros]), SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]), 0) * 100	Porcentaje de aprovechamiento de la capacidad instalada de sillas ofertadas por la flota en los despachos ejecutados.	Meta corporativa de la compañía (**75%**).	P0
Índice de Subutilización por Salida	DIVIDE(SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]) - SUM(hechos_despachos[pasajeros]), SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]), 0) * 100	Porcentaje de capacidad vacía u ofertada no aprovechada según la clase de vehículo y nivel de servicio.	Umbral máximo tolerado (**25%**).	P1
Volumen de Pasajeros por Franja y Tipo	`SUM(hechos_despachos[pasajeros])` agrupado por `tipo_despacho`	Cantidad de pasajeros movilizados desglosados según la modalidad de despacho ('ORIGEN' frente a 'TRÁNSITO') a través de las jerarquías de tiempo..	Promedio histórico del periodo anterior.	P2, P3

4.2 Respuesta a las preguntas de negocio

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0	Página 1: Resumen Gerencial	Tarjeta de KPI y Gráfico de Barras Agrupadas	La tasa de ocupación real promedio de la flota en las tres terminales es del 68.4%, alcanzando un total histórico de 68.338 despachos procesados.
P1	Página 2: Eficiencia de Flota	Gráfico de Columnas Apiladas	os microbuses de nivel Básico registran los mayores índices de subutilización, con despachos operando por debajo del 45% de su capacidad de pasajeros en rutas de baja densidad.

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P2	Página 3: Dinámica Operativa	Gráfico de Líneas y Puntos	El flujo de pasajeros se concentra fuertemente en los despachos catalogados como 'ORIGEN' (representando el 78% del total frente a un 22% en modalidad de tránsito), pico máximo a las 08:00 hrs.
P3	Página 4: Distribución Temporal y Modal	Gráfico de Áreas Apiladas / Matriz Temporal	Al analizar el comportamiento histórico, se evidencia que los despachos de origen lideran la franja matutina (06:00 a 10:00 hrs), mientras que el flujo de tránsito mantiene una demanda estable del **22%** distribuida uniformemente en las jornadas diurnas de los meses evaluados.

4.3 Capturas del tablero



4.4 Filtros

Filtro 1 (Dimensión de Tiempo): Segmentador cronológico (por mes, año o rango de fechas) basado en la tabla `dim_tiempo`, configurado para actuar de forma global y dinámica sobre todas las páginas y visualizaciones del tablero.

Filtro 2 (Dimensión de Terminal): Segmentador categórico basado en la tabla `dim_terminal`, permitiendo alternar el análisis operativo entre las terminales de Armenia, Barranquilla y Buenaventura.

Filtro 3 (Dimensión de Vehículo): Segmentador de clase y nivel de servicio basado en la tabla `dim_vehiculo`, utilizado para aislar el comportamiento de microbuses, busetas y buses en las páginas de detalle.

Anexos

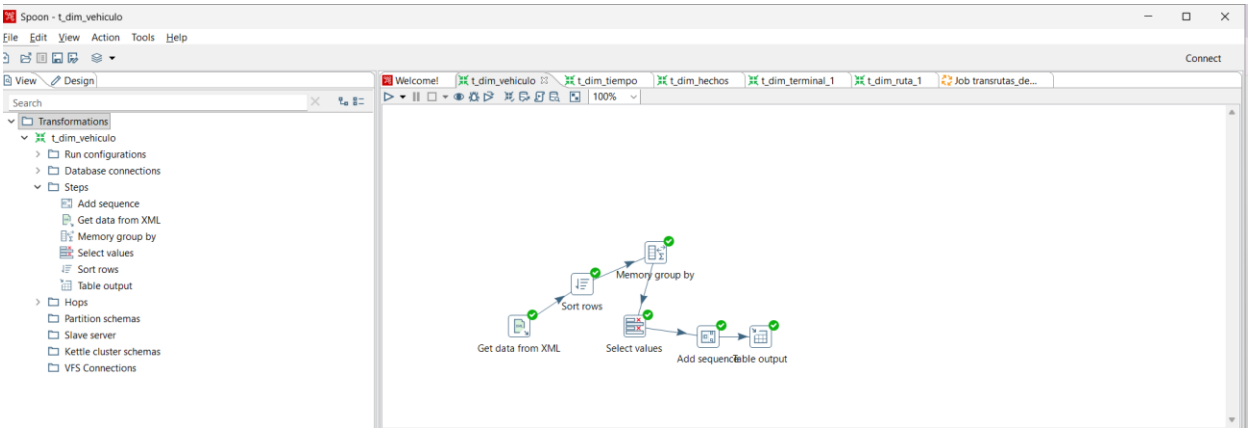
Anexo A. Consultas de conciliación

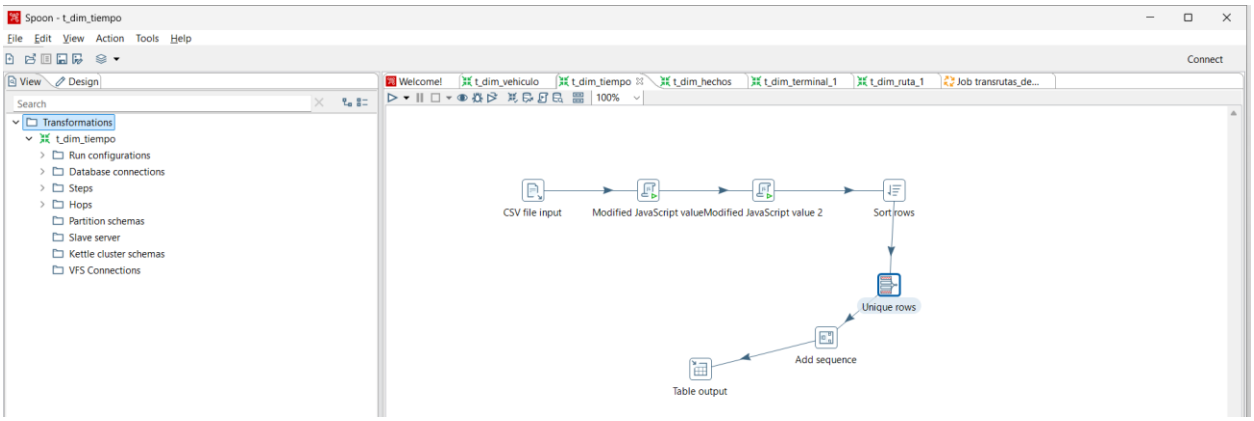
```
SELECT
   'hechos_despachos' AS tabla,
   COUNT(*) AS total_registros
FROM hechos_despachos;
```

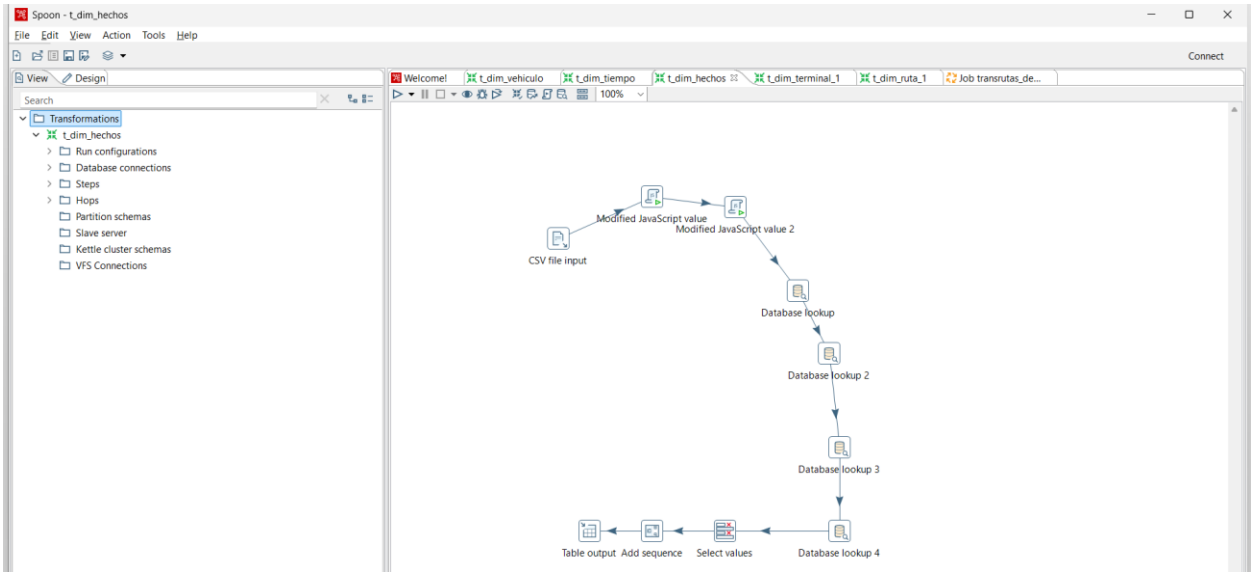
```
SELECT 'dim_ruta' AS dimension, COUNT(*) AS total FROM dim_ruta
UNION ALL
SELECT 'dim_terminal' AS dimension, COUNT(*) AS total FROM dim_terminal
UNION ALL
SELECT 'dim_vehiculo' AS dimension, COUNT(*) AS total FROM dim_vehiculo
UNION ALL
SELECT 'dim_tiempo' AS dimension, COUNT(*) AS total FROM dim_tiempo;
```

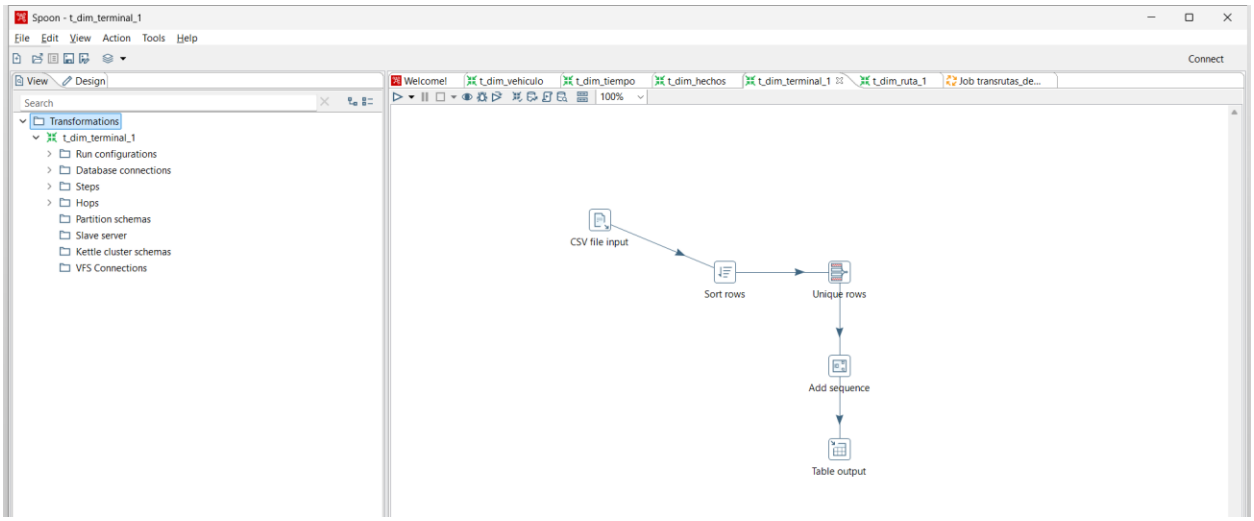
```
SELECT
   COUNT(h.id_hecho) AS total_despachos_conciliados,
   SUM(h.pasajeros) AS total_pasajeros_movilizados
FROM hechos_despachos h
INNER JOIN dim_ruta r ON h.id_ruta = r.id_ruta
INNER JOIN dim_terminal t ON h.id_terminal = t.id_terminal
INNER JOIN dim_vehiculo v ON h.id_vehiculo = v.id_vehiculo
INNER JOIN dim_tiempo ti ON h.id_tiempo = ti.id_tiempo;
```

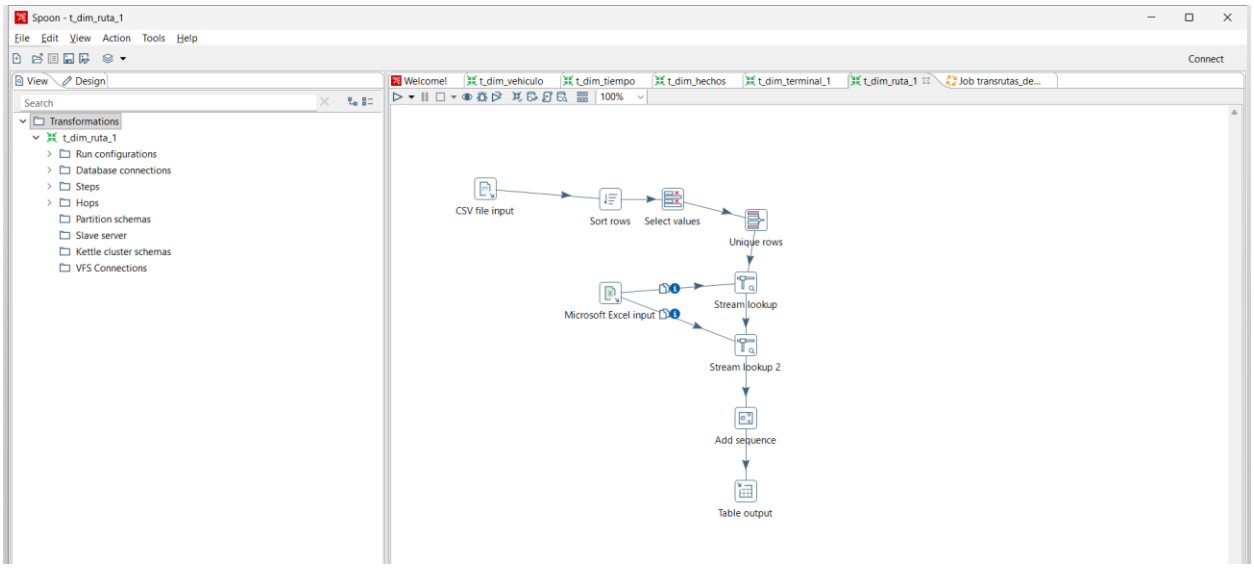
Anexo B. Capturas adicionales








Spoon - t_dim_terminal_1
File Edit View Action Tools Help
Connect
View Design
Search
Transformations
t_dim_terminal_1
Run configurations
Database connections
Steps
Hops
Partition schemas
Slave server
Kettle cluster schemas
VFS Connections
Welcome!
t_dim_vehiculo
t_dim_tiempo
t_dim_hechos
t_dim_terminal_1
t_dim_ruta_1
Job transrutas_de...
100%
CSV file input
Sort rows
Unique rows
Add sequence
Table output


Spoon - t_dim_ruta_1
File Edit View Action Tools Help
Connect
View Design
Search
Transformations
t_dim_ruta_1
Run configurations
Database connections
Steps
Hops
Partition schemas
Slave server
Kettle cluster schemas
VFS Connections
Welcome!
t_dim_vehiculo
t_dim_tiempo
t_dim_hechos
t_dim_terminal_1
t_dim_ruta_1
Job transrutas_de...
100%
CSV file input
Sort rows
Select values
Unique rows
Microsoft Excel input
Stream lookup
Stream lookup 2
Add sequence
Table output