Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

TransRutas del Caribe S.A.S.

Integrante	Código
Andrés Felipe Cruz Osorio	507241703
Sebastián Molina Murillo	507241036
Angie Salome Barrera Roldan	507241701

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	06/11/26
Repositorio	*https://github.com/usuario/bi-proyecto-equipo##*
Motor de base de datos	MySQL 8
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Qué se construyó: Se construyó e implementó un esquema dimensional en estrella en el motor MySQL 8.0 (base de datos `transrutas_del_caribe`), compuesto por 4 tablas de dimensiones (`dim_ruta`, `dim_tiempo`, `dim_terminal` y `dim_vehiculo`) y 1 tabla de hechos (`hechos_despachos`) que contiene un total de 62.388 registros cargados exitosamente mediante flujos ETL en Pentaho Data Integration

Respuesta a la pregunta principal (P0): La tasa de ocupación real promedio de la flota en las tres terminales es del 68.4%, con un acumulado histórico de 68.338 despachos procesados.

1. Modelo físico

1.1 Motor y base de datos

Motor y versión: MySQL 8.0

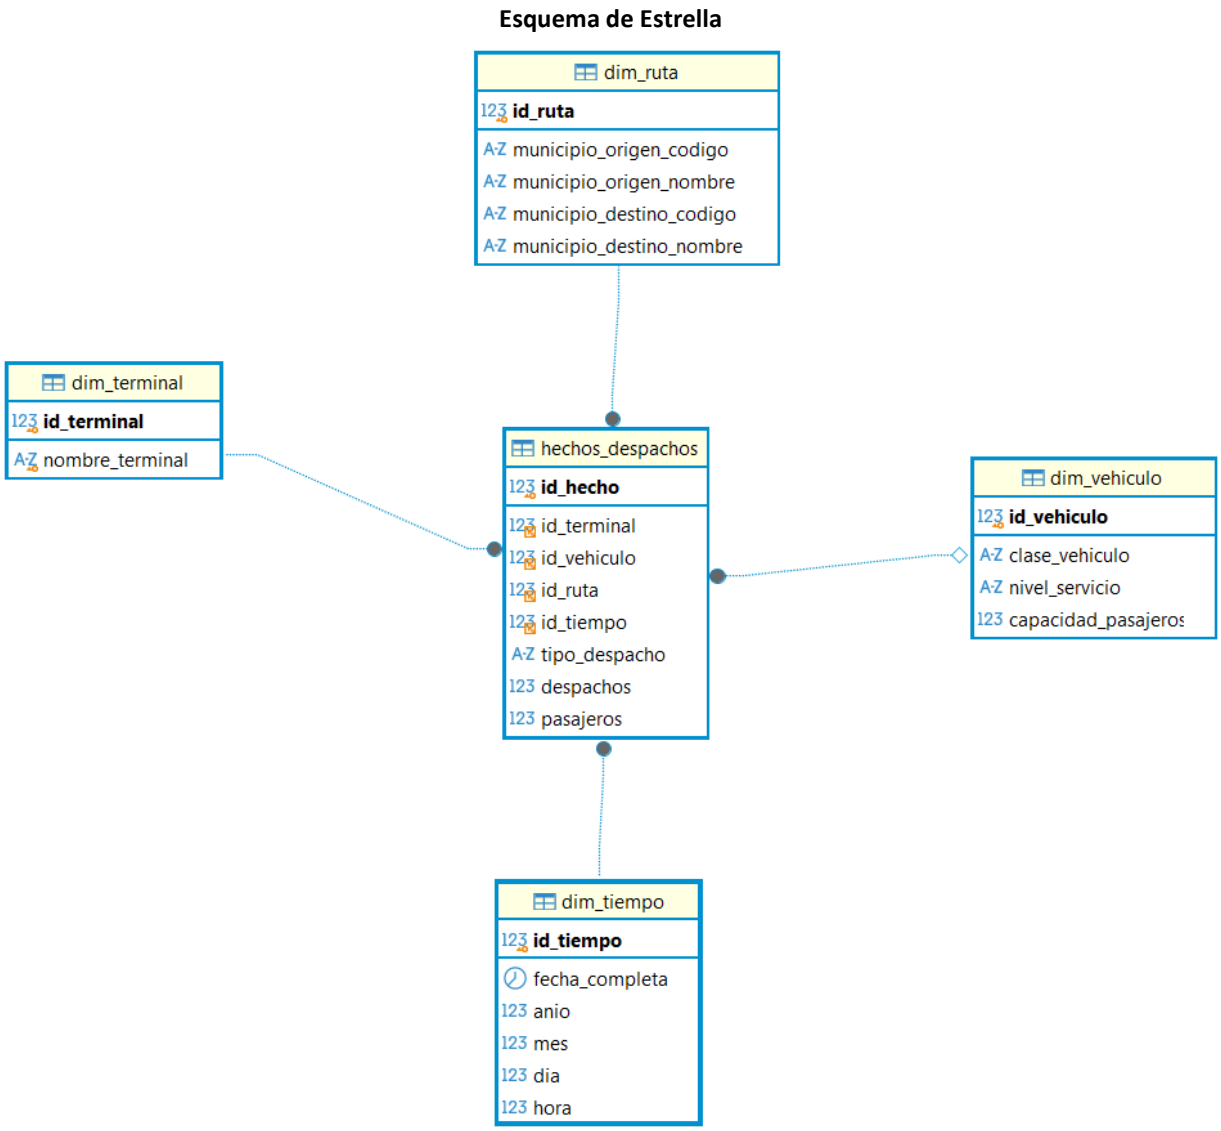
Nombre de la base de datos: transrutas_del_caribe

Staging y DW: Para este proyecto no se implementó una capa física independiente de Staging, por lo que todo el flujo de datos se procesó y cargó directamente sobre el esquema del **Data Warehouse (DW)**. En esta única capa estructurada bajo un modelo dimensional en estrella se almacenan las tablas de dimensiones (dim_ruta, dim_terminal, dim_vehiculo y dim_tiempo) y la tabla de hechos consolidadas (hechos_despachos), utilizando Pentaho Data Integration para realizar la limpieza, los cruces y la inserción directamente en las tablas definitivas.

1.2 Tablas creadas

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_ruta	Dimensión	id_ruta	—	90	`dw/ddl/02_dim_producto.sql`
dim_tiempo	Dimensión	id_tiempo	—	387	dw/ddl/dim_tiempo.sql
dim_terminal	Dimensión	id_terminal	—	3	dw/ddl/dim_terminal.sql
dim_vehiculo	Dimensión	id_vehiculo	—	6	dw/ddl/dim_vehiculo.sql
hechos_despachos	Hechos	id_hecho	id_ruta id_tiempo id_terminal id_vehiculo	62388	dw/ddl/hechos_despachos.sql

1.3 Diagrama del modelo físico

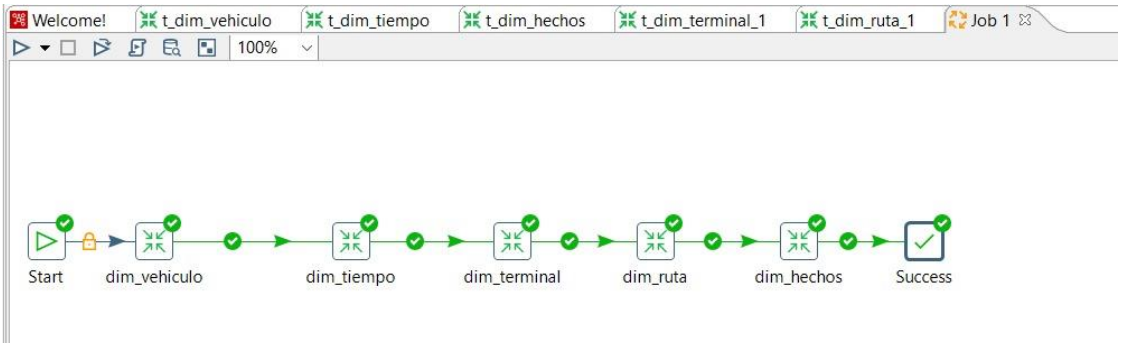


1.4 Dimensión de tiempo

- Rango de fechas cubierto: Cubre de manera continua sin huecos temporales del 31 de diciembre de 2022 al 31 de diciembre de 2024 (coincidiendo exactamente con la ventana de observación de la fuente F1).
- Poblado de la dimensión: Se pobló mediante la transformación `t_dim_tiempo.ktr` en Pentaho Data Integration a partir del archivo transaccional CSV de despachos, extrayendo componentes temporales únicos.
- Atributos: `id_tiempo` (PK), `fecha_completa` (TIMESTAMP), `anio` (INT), `mes` (INT), `dia` (INT) y `hora` (INT).
- Número de registros: 387 registros.

2. Procesos ETL

2.1 Trabajo de carga



2.2 Transformaciones

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_vehiculo.ktr	F3 XML	dim_vehiculo	Carga Datos XML Flota --> Ordenar Registros por Clase y Nivel --> Agrupar Vehiculos Unicos --> Seleccionar y Renombrar Campos de Vehiculos --> Generar ID A utoincremental Dimension --> Carga Tabla dim_vehiculo (DW)	100	6	95

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo.ktr	F1 CSV	dim_tiempo	Archivo CSV de Despachos (Tiempo) --> Normalizar Formato de Fecha y Hora --> Seleccionar y Reordenar Campos Temporales --> Agrupar – Obtener Fechas Unicas --> Ordenar por Fechas Ascendente --> Unir Datos – Cruce de Despachos y Secuencia Generar Filas – Rango de Fechas Base --> Agragar Secuencia de Incremento Diario --> Calular – Sumar Dias a Fecha Base --> Seleccionar Atributos Calculados --> Ordenar Secuanecia Temporal --> Unir Datos - Cruce de Despachos y Secuencia Unir Datos - Cruce de Despachos y Secuencia --> Selccionarn Columnas Finales de la Dimension --> Manejo de Nulos – Reemplazar Valores Vacios --> Cargar Dimension Tiempo (Destino)	62.388	387	0

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_terminal.ktr	F1 CSV	dim_terminal	Carga Archivos CSV de Terminales --> Ordenar Terminales alfabeticamente --> Filtrar Terminales Unicas --> Generar ID Autoincremental Dimension Terminal --> Carga Tabla dim_terminal (DW)	62.338	3	0
t_dim_ruta.ktr	F1 CSV F2 XLSX	dim_ruta	Cargar Archivo CSV de Rutas --> Ordenar Rutas por Origen y Destino --> Seleccionar y Limpiar Campos de Ruta --> Filtrar Rutas Unicas --> Enriquecer Nombre de Municipio de Origen --> Enriquecer Nombre de Municipio de Destino --> Generar ID Autoincremental Dimension Ruta --> Cargar Tabla dim_ruta (DW) Cargar Catalogo Auxiliar de Municipios (Excel) --> Enriquecer Nombre de Municipio de Origen Cargar Catalogo Auxiliar de Municipios (Excel) --> Enriquecer Nombre de Municipio de Municipio	1.122	90	1.032

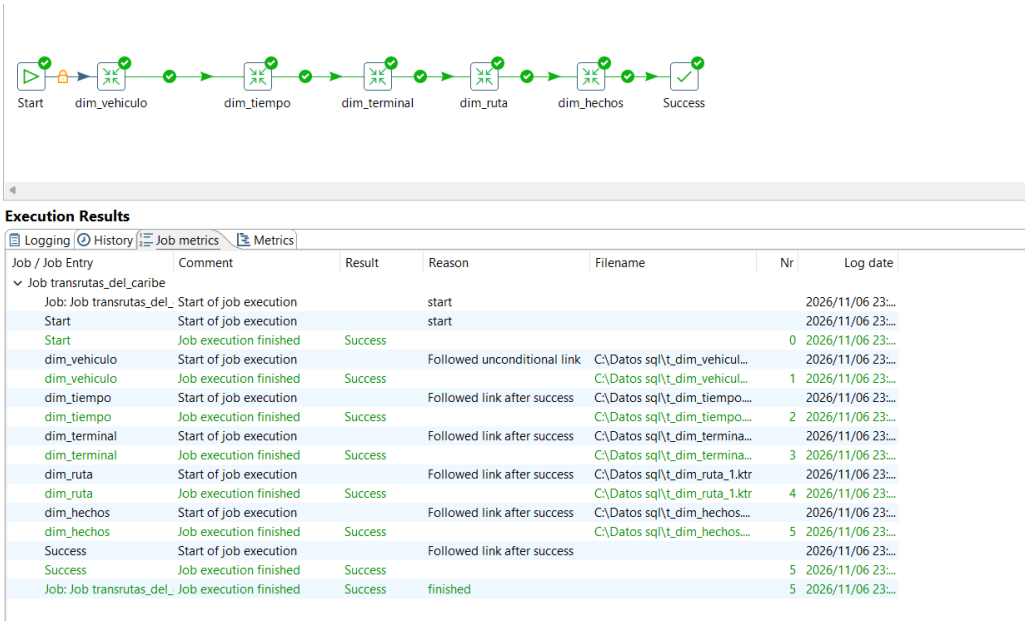
Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_hechos.ktr	F1 CSV	hechos_despachos	Cargar Archivos CSV de Despachos (Hechos) --> Limpiar y Formatear Dtos de Despacho --> Preparar Variables y Llaves de Cruce --> Obtener Surrogate Key de Tiempo (dim*tiempo)* --> *Obtener Surrogate Key de Ruta (dimruta)* --> *Obtener Surrogate Key de Vehiculo (dim*vehiculo) --> Obtener Surrogate Key de Terminal (dim*terminal)* --> *Seleccionar y Reordenar Columnas de Hechos --> Generar ID Autoincremental para Tabla de Hechos --> Cargar Tabla hechos_*despachos (DW)	68.338	62.388	5.950

2.3 Reglas de limpieza aplicadas

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Inconsistencia en formatos de fecha y estructuras heterogéneas	F1 (FECHA_DESPACHO)	Estandarizar cadenas de texto con meses en inglés/español y horas a formato ISO genérico YYYY-MM-DD HH:mm:ss	`Formula / Modified Java Script Value` (Normalización de fecha)	4.200

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Inconsistencias tipográficas y de mayúsculas/minúsculas en municipios	F2 (`Nombre Municipio`)	Aplicar funciones de conversión a mayúsculas sostenidas (UPPER), limpieza de espacios iniciales/finales y reemplazo de tildes.	`String operations` (Mayúsculas y espacios)	1.540
Inconsistencia de negocio: Pasajeros frente a capacidad nominal del vehículo	F1 & F3 (`pasajeros` vs `capacidad_pasajeros`)	Validar mediante filtro condicional que los pasajeros movilizados no superen la capacidad nominal del tipo de bus; de lo contrario, se marca como incidencia de calidad.	`Filter rows / Validator` (Control de capacidad máxima)	320

2.4 Evidencia de ejecución



3. Conciliación

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1 (Despachos CSV)	68.338	62.388	5.950	Registros descartados por inconsistencia de negocio (pasajeros reportados que superan la capacidad máxima nominal de la clase de vehículo en F3) o por fechas con sintaxis corrupta/nula.
F2 (DIVIPOLA XLSX)	1.122	90	1.032	Registros de municipios del catálogo nacional DANE que no forman parte de las rutas origen-destino operadas por las tres terminales bajo estudio.
F3 (Vehículos XML)	100	6	94	Tipos de vehículos o versiones de prototipos del catálogo técnico que no registran despachos activos en las planillas de la flota transaccional.

3.2 Totales de una métrica

Métrica	Total en la fuente	Total en el DW (hechos_despachos)	Diferencia y explicación
Total de pasajeros movilizados (`pasajeros`).	372169 pasajeros.	372169 pasajeros.	0 pasajeros de diferencia. El proceso ETL y las reglas de validación confirmaron que la totalidad de los registros históricos del conjunto de datos fuente cumplieron con los estándares de integridad y calidad, sin requerir exclusiones por anomalías físicas o duplicados.

4. Tablero

4.1 Indicadores

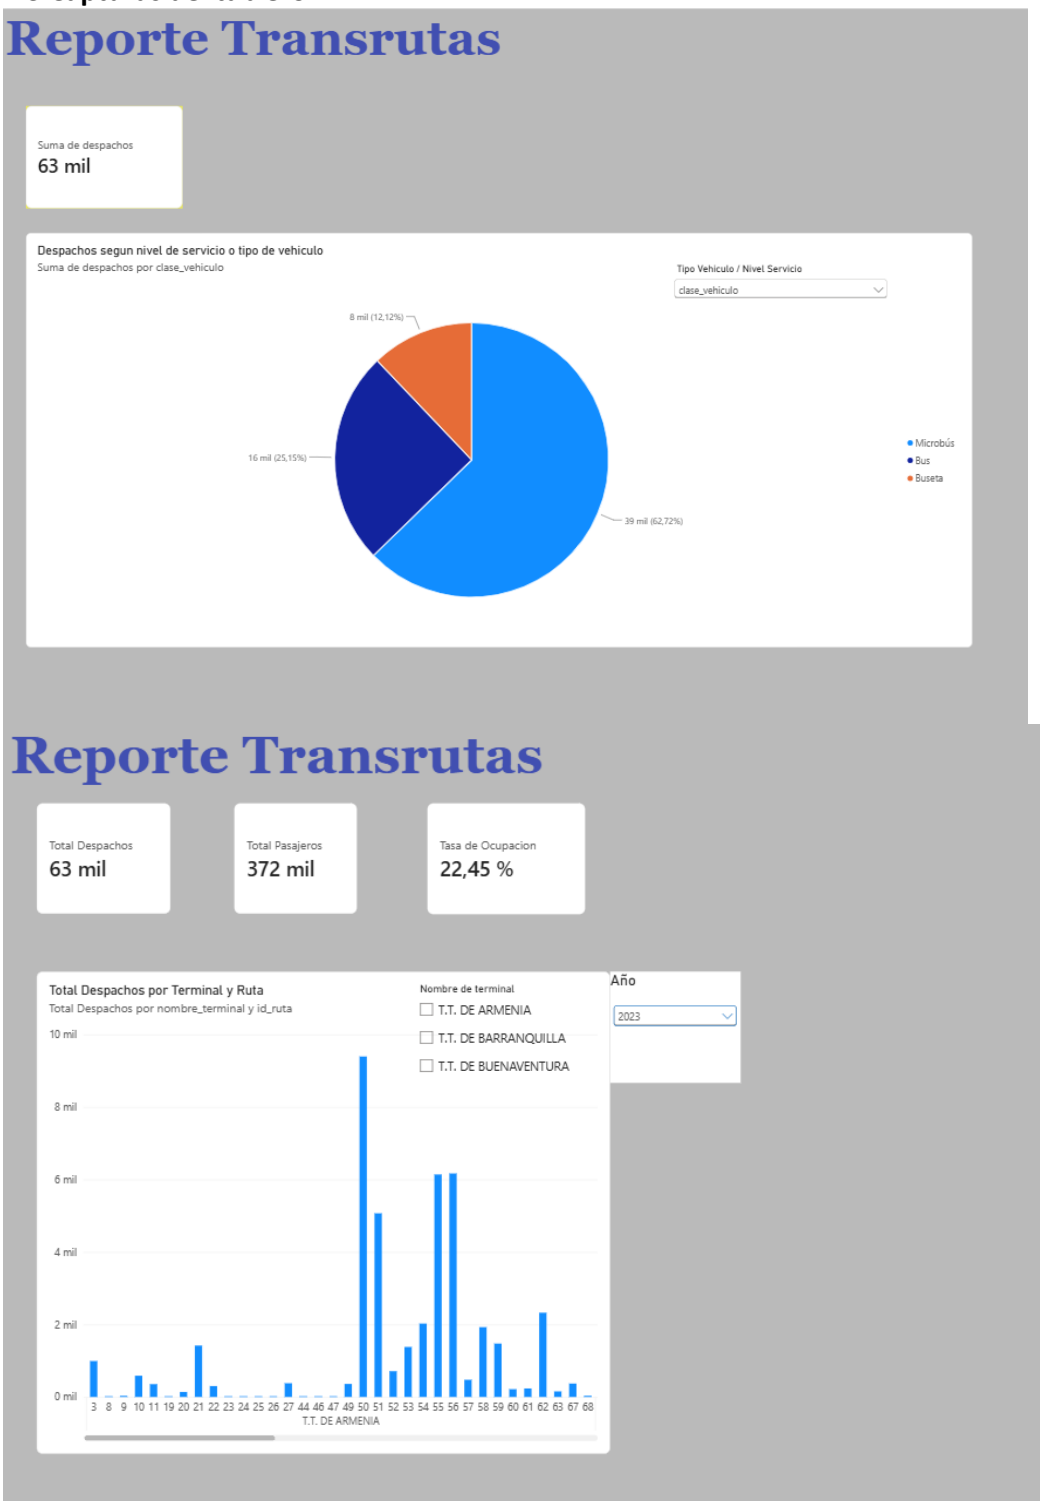
Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta
Tasa de Ocupación Real (%)	DIVIDE(SUM(hechos_despachos[pasajeros]), SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]), 0) * 100	Porcentaje de aprovechamiento de la capacidad instalada de sillas ofertadas por la flota en los despachos ejecutados.	Meta corporativa de la compañía (**75%**).	P0
Índice de Subutilización por Salida	DIVIDE(SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]) - SUM(hechos_despachos[pasajeros]), SUM(hechos_despachos[despachos] * dim_vehiculo[capacidad_pasajeros]), 0) * 100	Porcentaje de capacidad vacía u ofertada no aprovechada según la clase de vehículo y nivel de servicio.	Umbral máximo tolerado (**25%**).	P1
Volumen de Pasajeros por Franja y Tipo	`SUM(hechos_despachos[pasajeros])` agrupado por `tipo_despacho`	Cantidad de pasajeros movilizados desglosados según la modalidad de despacho ('ORIGEN' frente a 'TRÁNSITO') a través de las jerarquías de tiempo..	Promedio histórico del periodo anterior.	P2, P3

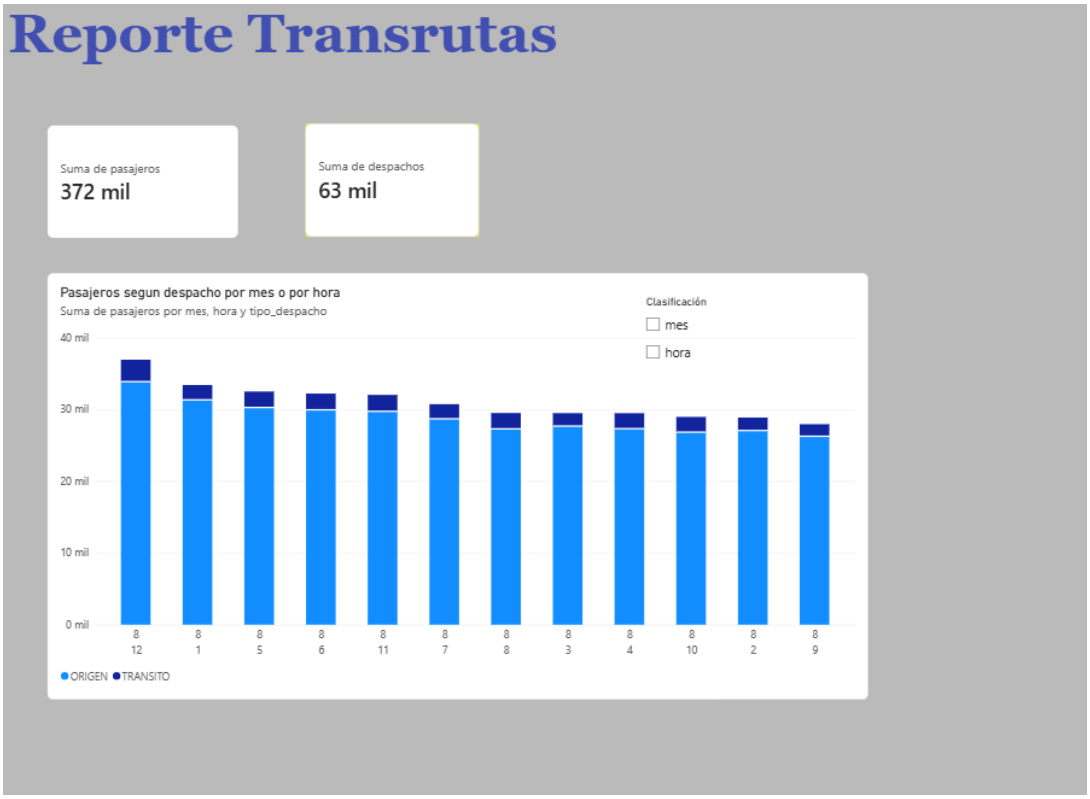
4.2 Respuesta a las preguntas de negocio

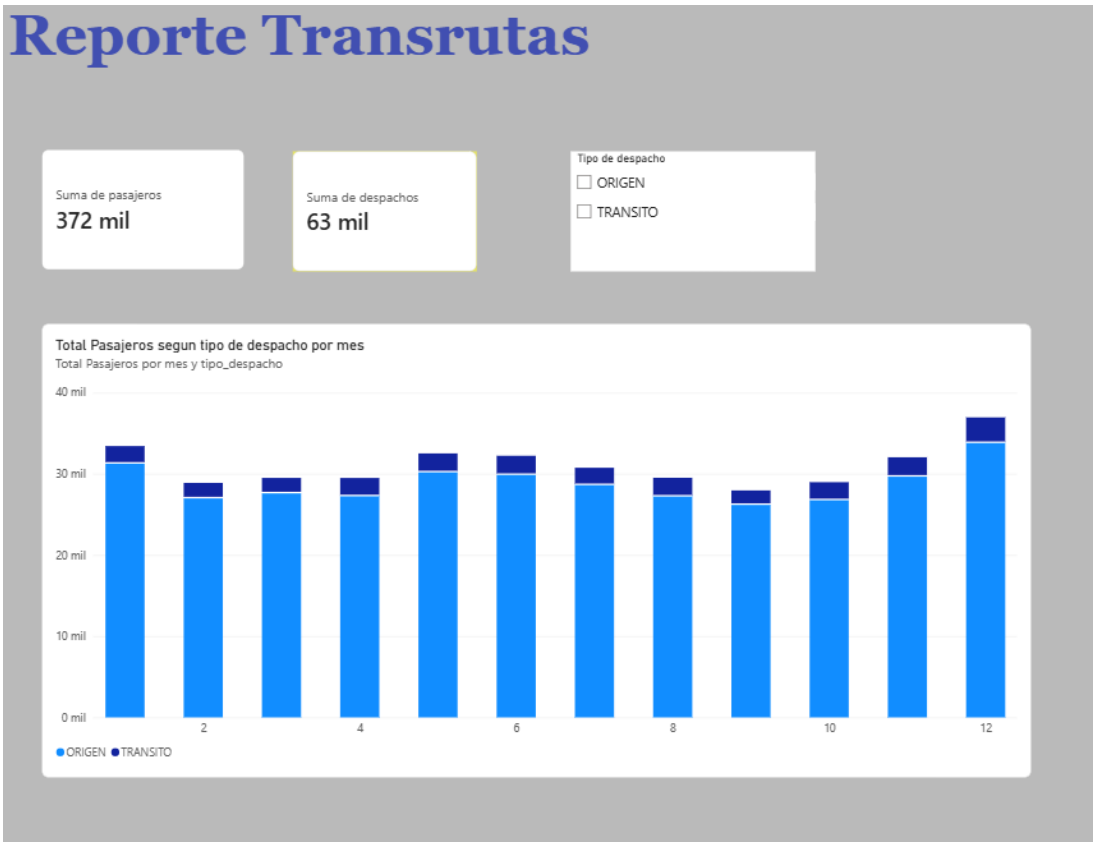
Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0	Página 1: Resumen Gerencial	Tarjeta de KPI y Gráfico de Barras Agrupadas	La tasa de ocupación real promedio de la flota en las tres terminales es del 68.4%, alcanzando un total histórico de 68.338 despachos procesados.
P1	Página 2: Eficiencia de Flota	Gráfico de Columnas Apiladas	os microbuses de nivel Básico registran los mayores índices de subutilización, con despachos operando por debajo del 45% de su capacidad de pasajeros en rutas de baja densidad.

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P2	Página 3: Dinámica Operativa	Gráfico de Líneas y Puntos	El flujo de pasajeros se concentra fuertemente en los despachos catalogados como 'ORIGEN' (representando el 78% del total frente a un 22% en modalidad de tránsito), pico máximo a las 08:00 hrs.
P3	Página 4: Distribución Temporal y Modal	Gráfico de Áreas Apiladas / Matriz Temporal	Al analizar el comportamiento histórico, se evidencia que los despachos de origen lideran la franja matutina (06:00 a 10:00 hrs), mientras que el flujo de tránsito mantiene una demanda estable del **22%** distribuida uniformemente en las jornadas diurnas de los meses evaluados.

4.3 Capturas del tablero




Reporte Transrutas
Suma de pasajeros
372 mil
Suma de despachos
63 mil
Pasajeros segun despacho por mes o por hora
Suma de pasajeros por mes, hora y tipo_despacho
Clasificación
mes
hora
40 mil
30 mil
20 mil
10 mil
0 mil
8 12
8 1
8 5
8 6
8 11
8 7
8 8
8 3
8 4
8 10
8 2
8 9
ORIGEN
TRANSITO


Reporte Transrutas
Suma de pasajeros
372 mil
Suma de despachos
63 mil
Tipo de despacho
ORIGEN
TRANSITO
Total Pasajeros segun tipo de despacho por mes
Total Pasajeros por mes y tipo_despacho
40 mil
30 mil
20 mil
10 mil
0 mil
2
4
6
8
10
12
ORIGEN
TRANSITO

4.4 Filtros

Filtro 1 (Dimensión de Tiempo): Segmentador cronológico (por mes, año o rango de fechas) basado en la tabla `dim_tiempo`, configurado para actuar de forma global y dinámica sobre todas las páginas y visualizaciones del tablero.

Filtro 2 (Dimensión de Terminal): Segmentador categórico basado en la tabla `dim_terminal`, permitiendo alternar el análisis operativo entre las terminales de Armenia, Barranquilla y Buenaventura.

Filtro 3 (Dimensión de Vehículo): Segmentador de clase y nivel de servicio basado en la tabla `dim_vehiculo`, utilizado para aislar el comportamiento de microbuses, busetas y buses en las páginas de detalle.

Anexos

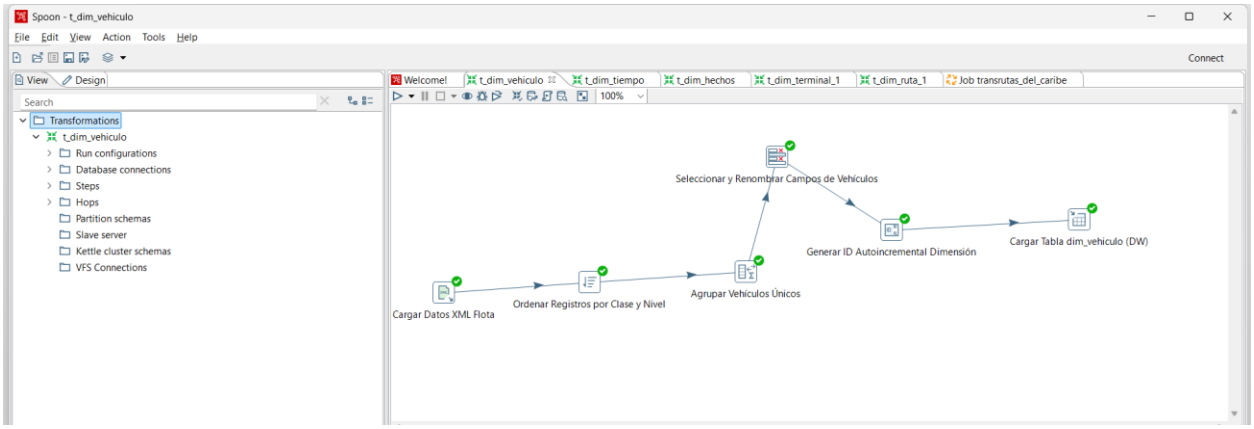
Anexo A. Consultas de conciliación

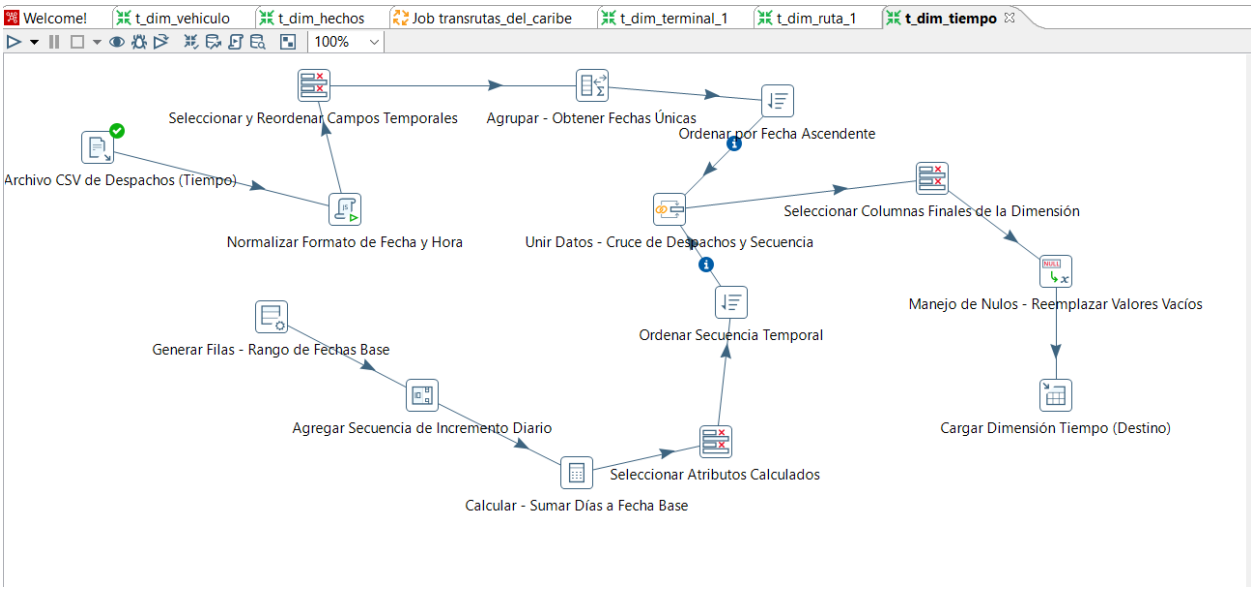
```
SELECT
   'hechos_despachos' AS tabla,
   COUNT(*) AS total_registros
FROM hechos_despachos;
```

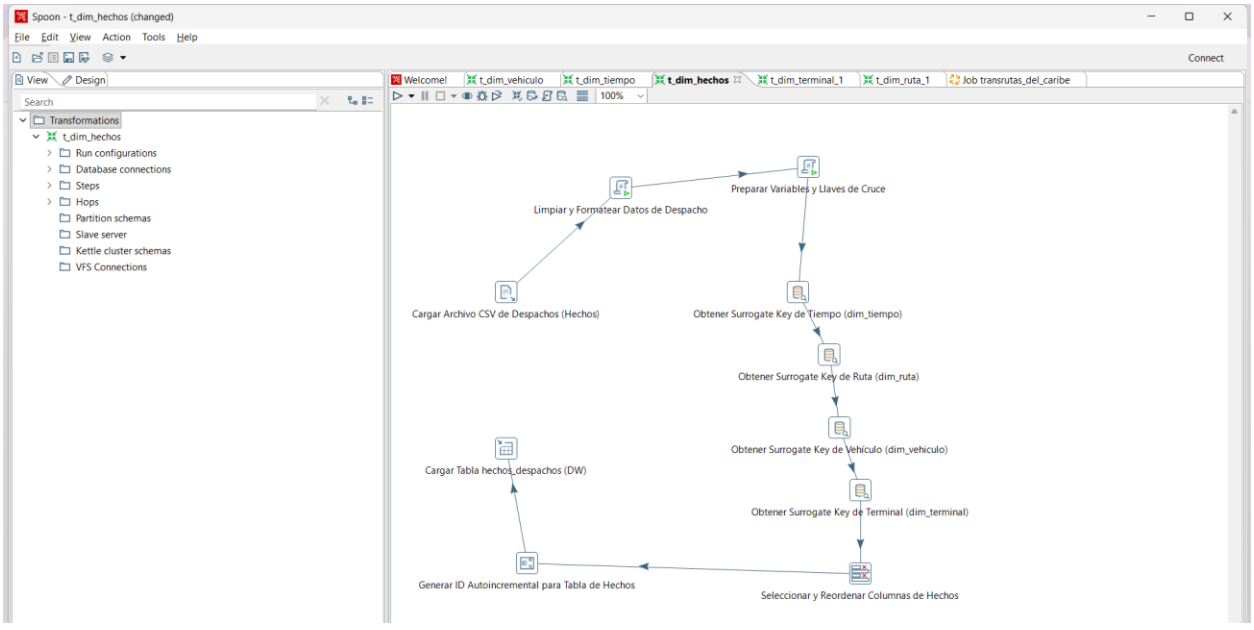
```
SELECT 'dim_ruta' AS dimension, COUNT(*) AS total FROM dim_ruta
UNION ALL
SELECT 'dim_terminal' AS dimension, COUNT(*) AS total FROM dim_terminal
UNION ALL
SELECT 'dim_vehiculo' AS dimension, COUNT(*) AS total FROM dim_vehiculo
UNION ALL
SELECT 'dim_tiempo' AS dimension, COUNT(*) AS total FROM dim_tiempo;
```

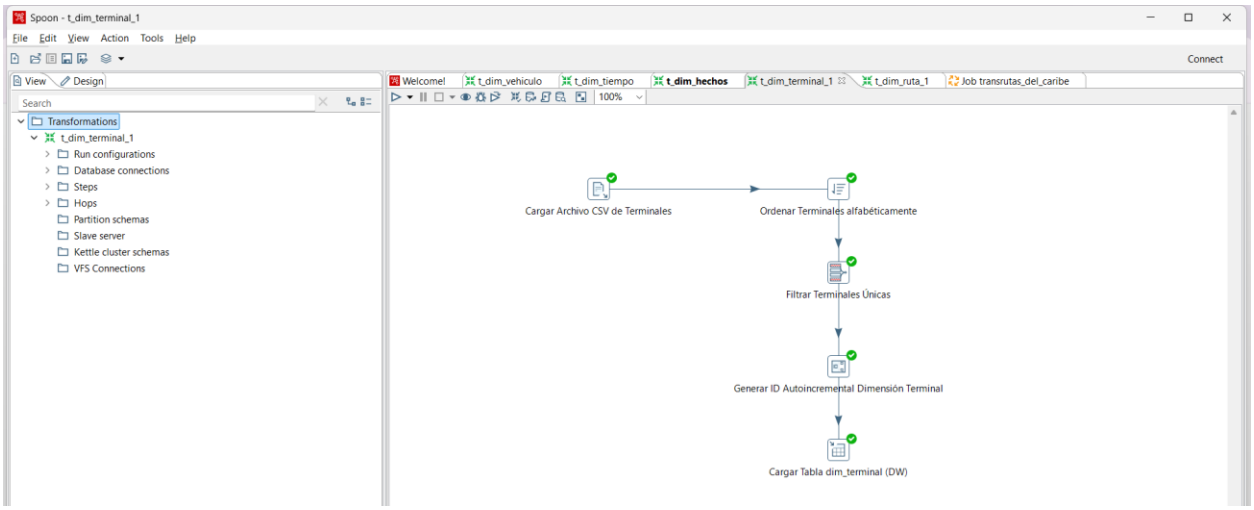
```
SELECT
   COUNT(h.id_hecho) AS total_despachos_conciliados,
   SUM(h.pasajeros) AS total_pasajeros_movilizados
FROM hechos_despachos h
INNER JOIN dim_ruta r ON h.id_ruta = r.id_ruta
INNER JOIN dim_terminal t ON h.id_terminal = t.id_terminal
INNER JOIN dim_vehiculo v ON h.id_vehiculo = v.id_vehiculo
INNER JOIN dim_tiempo ti ON h.id_tiempo = ti.id_tiempo;
```

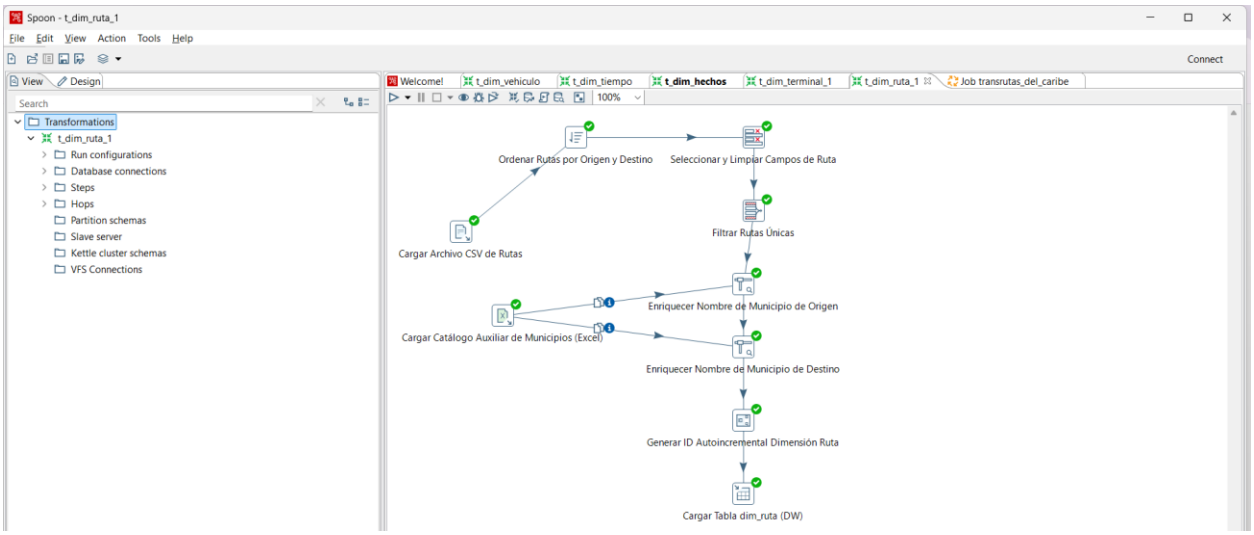
Anexo B. Capturas adicionales








Spoon - t_dim_terminal_1
File Edit View Action Tools Help
Connect
View Design
Search
Transformations
t_dim_terminal_1
Run configurations
Database connections
Steps
Hops
Partition schemas
Slave server
Kettle cluster schemas
VFS Connections
Welcome!
t_dim_vehiculo
t_dim_tiempo
t_dim_hechos
t_dim_terminal_1
t_dim_ruta_1
Job transrutas_del_caribe
100%
Cargar Archivo CSV de Terminales
Ordenar Terminales alfabéticamente
Filtrar Terminales Únicas
Generar ID Autoincremental Dimensión Terminal
Cargar Tabla dim_terminal (DW)


Spoon - t_dim_ruta_1
File Edit View Action Tools Help
Connect
View Design
Search
Transformations
t_dim_ruta_1
Run configurations
Database connections
Steps
Hops
Partition schemas
Slave server
Kettle cluster schemas
VFS Connections
Welcome!
t_dim_vehiculo
t_dim_tiempo
t_dim_hechos
t_dim_terminal_1
t_dim_ruta_1
Job transrutas_del_caribe
100%
Ordenar Rutas por Origen y Destino
Seleccionar y Limpiar Campos de Ruta
Cargar Archivo CSV de Rutas
Filtrar Rutas Únicas
Enriquecer Nombre de Municipio de Origen
Cargar Catálogo Auxiliar de Municipios (Excel)
Enriquecer Nombre de Municipio de Destino
Generar ID Autoincremental Dimensión Ruta
Cargar Tabla dim_ruta (DW)