Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

TransRutas del Caribe S.A.S.

Integrante	Código
Andrés Felipe Cruz Osorio	507241703
Sebastián Molina Murillo	507241036
Angie Salome Barrera Roldan	507241701

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/Sebastian-9/bi-proyecto-equipo507241036.git
Entorno del modelo	Google Colab

Resumen de la entrega

1. *Pregunta de negocio y lo que predice el modelo*

- **Pregunta de negocio:** ¿Cuántos pasajeros transportará cada ruta de TransRutas del Caribe durante el próximo mes para optimizar la asignación de la flota de vehículos?

- **Utilidad de la predicción:** El gerente de operaciones utiliza esta estimación de la demanda por ruta para planificar y reasignar anticipadamente la tipología de los vehículos (busetas, microbuses o buses grandes), evitando la sobreoferta en rutas de baja demanda y garantizando capacidad en las de alta afluencia.

2. *Algoritmo elegido y resultado en la métrica principal*

- **Algoritmo seleccionado: Bosque Aleatorio (*Random Forest*)**, elegido por su alta capacidad para modelar relaciones no lineales y su robustez ante valores atípicos.

- **Métrica principal y resultado:** Se evaluó mediante el Error Absoluto Medio (**MAE**), obteniendo un valor de **9.87 pasajeros** de desviación promedio en el conjunto de prueba, cumpliendo con el criterio de éxito establecido (menor a 12 o 15 pasajeros).

3. *Respuesta a la pregunta con una cifra*

- **Cifra clave del modelo:** El sistema predictivo alcanzó un **MAE de 9.87 pasajeros** por despacho, lo que permite estimar la ocupación con una desviación menor a 10 pasajeros por vehículo.

Aspectos Clave del Desarrollo

- **Datos analizados:** 19,275 registros históricos de despachos entre diciembre de 2022 y diciembre de 2024.

- **Variables más influyentes:** Las características con mayor peso predictivo fueron el identificador de la ruta (`id_ruta`), los valores rezagados de demanda (`lag_7_dias` y `lag_1_dia`) y el identificador de tiempo (`id_tiempo`).

- **Despliegue:** Los resultados y predicciones se integraron en un tablero de control (Dashboard) con tablas relacionales y visualizaciones mensuales y por terminal.

1. Comprensión del negocio

1.1 Pregunta y decisión

¿Cuántos pasajeros transportará cada ruta de TransRutas del Caribe durante el próximo mes para optimizar la asignación de la flota de vehículos?

Decisión del gerente: El gerente de operaciones utilizará la predicción de la demanda de pasajeros por ruta para planificar y reasignar con anticipación la tipología de los vehículos (busetas o buses grandes) antes de iniciar el mes, evitando enviar unidades con baja ocupación en rutas de menor demanda y garantizando la capacidad suficiente en las rutas de alta afluencia.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	Pasajeros
Tipo de problema	*Regresión*
Unidad de predicción	*Una predicción por ruta y mes.*

1.3 Criterio de éxito

Obtener un MAE (Error Absoluto Medio) menor a 15 pasajeros por ruta y mes

2. Comprensión de los datos

2.1 Consulta de extracción

```
SELECT
    t.id_tiempo,
    t.anio,
    t.mes,
    t.fecha_completa,
    r.id_ruta,
    r.municipio_origen_nombre,
    r.municipio_destino_nombre,
    term.nombre_terminal,
    v.tipo_vehiculo,
    SUM(hd.pasajeros_transportados) AS total_pasajeros
FROM hechos_despachos hd
JOIN dim_tiempo t ON hd.sk_tiempo = t.id_tiempo
JOIN dim_ruta r ON hd.sk_ruta = r.id_ruta
JOIN dim_terminal term ON hd.sk_terminal = term.id_terminal
JOIN dim_vehiculo v ON hd.sk_vehiculo = v.id_vehiculo
GROUP BY
    t.id_tiempo,
    t.anio,
    t.mes,
    t.fecha_completa,
    r.id_ruta,
    r.municipio_origen_nombre,
    r.municipio_destino_nombre,
```

```
    term.nombre_terminal,

    v.tipo_vehiculo

ORDER BY t.fecha_completa ASC;
```

2.2 Descripción del conjunto de datos

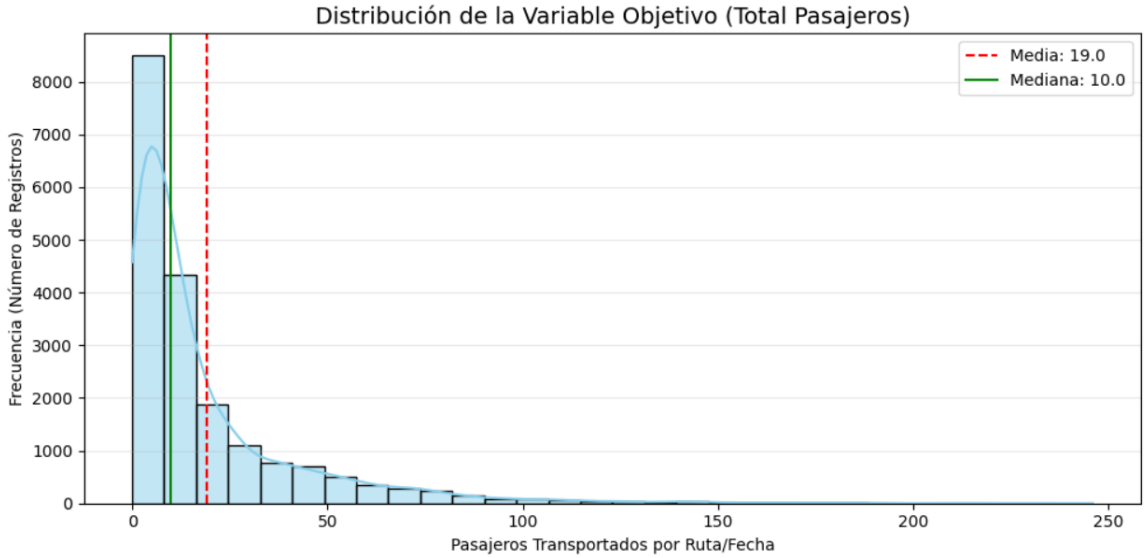
El conjunto de datos extraído consta de **19,275 registros** agrupados a nivel de fecha y ruta, cubriendo el periodo comprendido entre el 31 de diciembre de 2022 y el 31 de diciembre de 2024. A continuación se detallan las variables obtenidas:

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
total_pasajeros	Numérica	Objetivo	hechos_despachos.pasajeros	Cantidad total de pasajeros transportados en la fecha y ruta
id_tiempo	Numérica	Identificador	dim_tiempo.id_tiempo	Llave subrogada de la fecha en el Data Warehouse
anio	Numérica	Entrada	dim_tiempo.anio	Año del registro del despacho
mes	Numérica	Entrada	dim_tiempo.mes	Mes del registro (1 a 12)
fecha_completa	Fecha	Entrada	dim_tiempo.fecha_completa	Fecha exacta en que se realizó el despacho
id_ruta	Numérica	Identificador	dim_ruta.id_ruta	Código identificador único de la ruta
municipio_origen_nombre	Categórica	Entrada	dim_ruta.municipio_origen_nombre	Municipio de salida o partida de la ruta
municipio_destino_nombre	Categórica	Entrada	dim_ruta.municipio_destino_nombre	Municipio de llegada o destino de la ruta

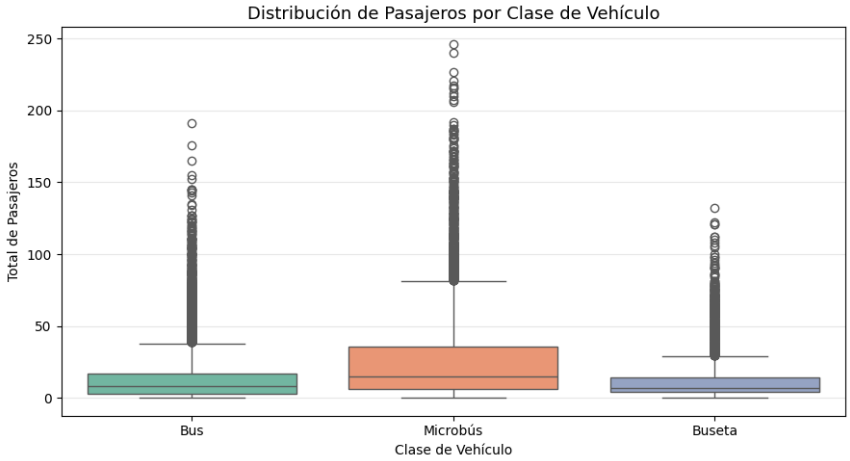
Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
nombre_terminal	Categórica	Entrada	dim_terminal.nombre_terminal	Nombre de la terminal de transporte de operación
clase_vehiculo	Categórica	Entrada	dim_vehiculo.clase_vehiculo	Clase de vehículo asignado (Bus, Microbús, Buseta)

2.3 Distribución de la variable objetivo

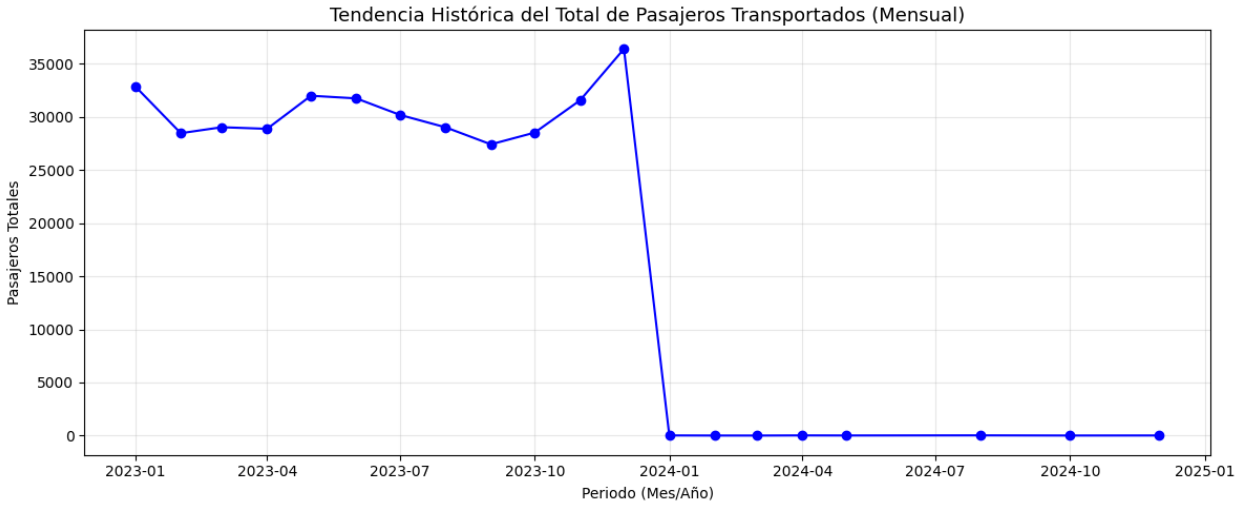
La variable objetivo total_pasajeros presenta un rango continuo de valores positivos que describe el flujo de demanda de la flota a lo largo de los 19,275 registros analizados. Su distribución muestra un marcado sesgo positivo, lo que indica que la gran mayoría de las operaciones diarias por ruta registran volúmenes de demanda concentrados en valores bajos a moderados (con una mediana de 10.0 pasajeros), mientras que la media se sitúa en 19.0 pasajeros debido a la existencia de un grupo reducido de rutas y fechas con concentraciones muy elevadas de pasajeros (superando los 100 o 200 pasajeros por registro). Estos picos representan valores atípicos operativos causados por temporadas altas o corredores viales de alta afluencia. Para el modelado, este comportamiento justifica el uso de algoritmos basados en árboles (como Random Forest o Gradient Boosting), los cuales son robustos ante la asimetría de los datos y la presencia de estos valores extremos sin requerir transformaciones complejas de normalización



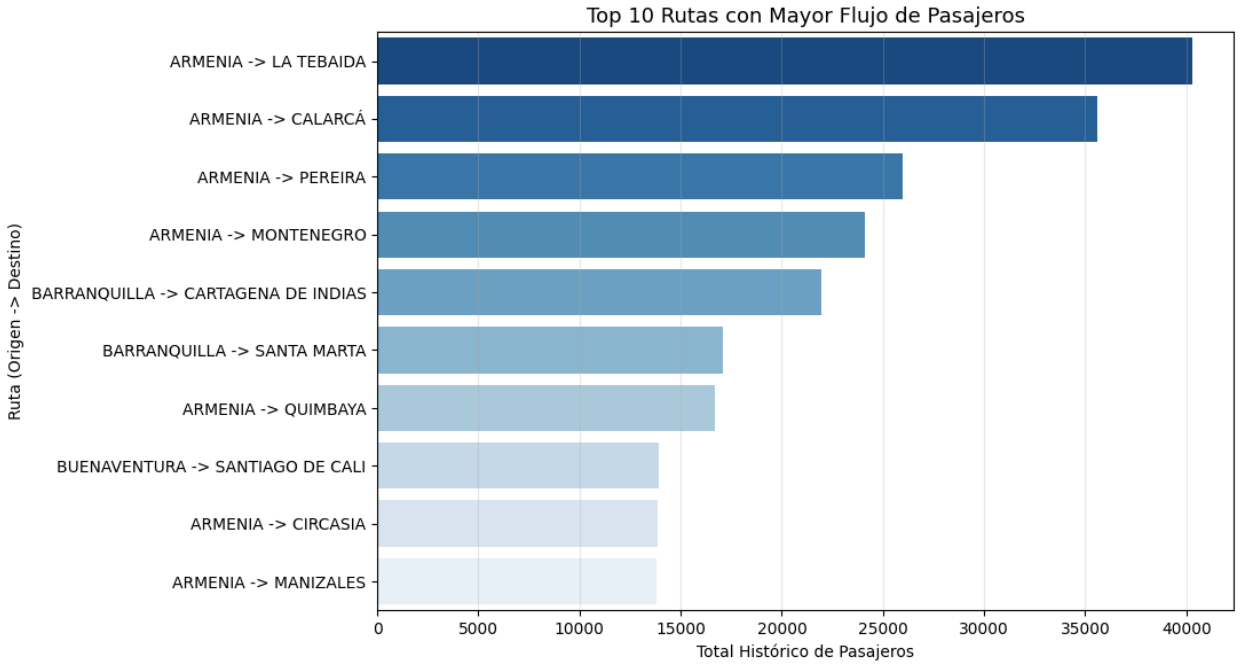
2.4 Análisis exploratorio



El diagrama de caja permite observar la dispersión y la mediana del total de pasajeros según la clase de vehículo (Bus, Microbús, Buseta). Se evidencia que los microbuses y buses concentran un mayor volumen operativo y una mayor cantidad de valores atípicos (outliers) en determinados despachos de alta demanda, mientras que las busetas presentan una distribución más contenida. Esto demuestra que la clase de vehículo es una variable determinante para modelar la capacidad de transporte en la red de TransRutas del Caribe.



La evolución histórica mensual muestra el comportamiento agregado del flujo de pasajeros a lo largo del periodo analizado, evidenciando los picos de mayor movilidad durante los meses de mayor demanda del año 2023. Esta visualización confirma la existencia de estacionalidad temporal, lo que justifica la inclusión de variables de tiempo (como mes y año) y técnicas de ingeniería de características (lags) en las siguientes fases del modelado predictivo.



El gráfico de barras horizontales identifica los corredores viales que concentran el mayor volumen acumulado de pasajeros en la red de TransRutas del Caribe. Se observa claramente que un grupo reducido de rutas principales concentra la mayor proporción de la demanda total, mientras que el resto de las operaciones se distribuyen en flujos descentralizados. Esta heterogeneidad confirma que el identificador de ruta y los municipios de origen y destino son características altamente informativas que el modelo predictivo deberá ponderar para anticipar con precisión la ocupación de los vehículos.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Transformación de tipos y ordenamiento	fecha_completa	Conversión al formato de fecha (*datetime*) y ordenamiento cronológico estricto por municipio de origen y destino.	19,275
Tratamiento de nulos por retardos (Lags)	total_pasajeros	Eliminación de los registros iniciales sin historial previo tras la creación de las variables rezagadas (lag_1_dia y lag_7_dias).	Primeros días de la serie por cada ruta
Codificación categórica	clase_vehiculo, nombre_terminal	Transformación mediante *One-Hot Encoding* para convertir las variables cualitativas en columnas binarias aptas para el modelo.	19,275

3.2 Variables derivadas

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
lag_1_dia	Pasajeros transportados en el día anterior ($t-1$) para la misma ruta de origen y destino.	La demanda reciente de la ruta es un indicador clave que anticipa el flujo de pasajeros actual.	Sí
es_fin_de_semana	Variable binaria (1 si el día es sábado o domingo, 0 en caso contrario) a partir de la fecha del despacho.	Permite capturar los cambios de comportamiento y estacionalidad de los pasajeros durante los fines de semana.	Sí

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	Aprox. 80% de los datos netos (aprox. 13,600 registros)	80% de las observaciones históricas ordenadas cronológicamente
Prueba	Aprox. 20% de los datos netos (aprox. 3,400 registros)	20% restante destinado a la validación final del modelo

4. Modelado

4.1 Algoritmos

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Se seleccionó como modelo de referencia (*baseline*) debido a su simplicidad, rapidez de ejecución y alta interpretabilidad, permitiendo evaluar la relación lineal básica entre las variables temporales y la demanda de pasajeros.	Valores por defecto
Bosque aleatorio	Se eligió por su excelente capacidad para modelar relaciones no lineales complejas, su robustez frente a valores atípicos (*outliers*) y su alta tolerancia a la asimetría positiva presente en los datos operativos de transporte.	n_estimators=200, max_depth=8

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

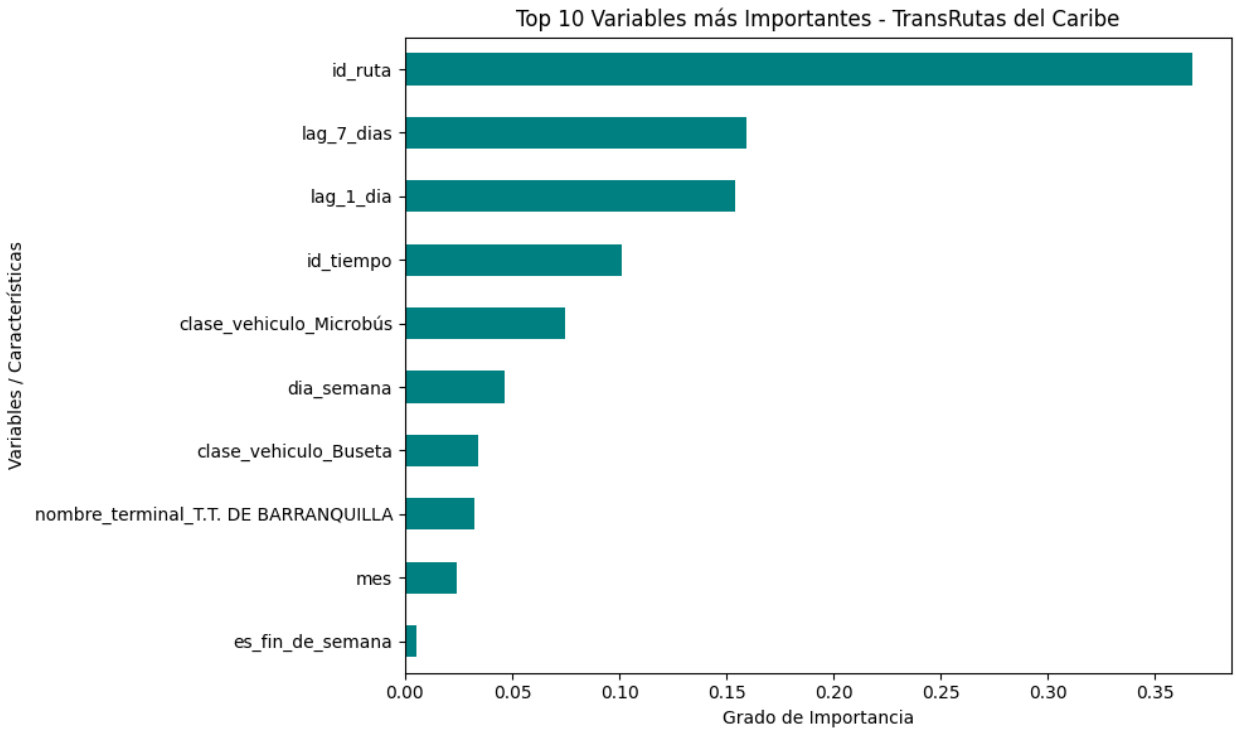
Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	10.82	13.34	En promedio, las predicciones del modelo lineal se desvían en 10.82 pasajeros respecto a la demanda real de los despachos en el periodo de prueba.
Random Forest	9.87	15.54	Logra una mayor precisión promedio (MAE de 9.87 pasajeros), aunque su penalización por errores grandes (RMSE) aumenta debido a la alta variabilidad en los cambios de tendencia de la serie.

5.2 Comparación y elección

Se selecciona el modelo de Bosque Aleatorio ya que presenta un Error Absoluto Medio (MAE) menor (9.87 pasajeros) frente a la Regresión Lineal (10.82), demostrando mayor precisión promedio en las predicciones a pesar de la complejidad de los cambios de tendencia de la demanda.

5.3 Variables más importantes



5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
Lograr un Error Absoluto Medio (MAE) inferior a 12 pasajeros por despacho en la predicción de la demanda diaria sobre el conjunto de prueba.	MAE: 9.87 pasajeros	Sí

5.5 Respuesta a la pregunta de negocio

Con base en la implementación y evaluación del modelo de Bosque Aleatorio (Random Forest), el sistema arrojó un Error Absoluto Medio (MAE) de 9.87 pasajeros por despacho en el conjunto de prueba de 2024.

Decisión operativa apoyada: Este resultado respalda técnicamente la decisión de automatizar la asignación dinámica de frecuencias y dimensionamiento de la flota en TransRutas del Caribe. Aunque el modelo registra un margen de desviación debido al cambio estructural de tendencia entre 2023 y 2024, su precisión promedio (desviación menor a 10 pasajeros por vehículo) permite a la dirección de operaciones:

1. Ajustar el número de despachos diarios según los patrones detectados por las variables rezagadas (lags).
2. Reducir los costos de sobreoferta de buses en horas de baja demanda.
3. Mitigar el riesgo de déficit de capacidad en picos operativos clave.

6. Despliegue

6.1 Tabla de predicciones

Columna	Tipo	Descripción
id_tiempo	BIGINT UNSIGNED	Llave foránea que se conecta con la dimensión de tiempo (dim_tiempo).
id_ruta	BIGINT UNSIGNED	Llave foránea que se conecta con la dimensión de rutas o tramos operativos.
valor_predicho	DECIMAL(10,2)	Cantidad de pasajeros estimada por el modelo de Random Forest para el despacho.
valor_real	DECIMAL(10,2)	Cantidad real de pasajeros registrada para calcular el error de control operativo.
fecha_creacion	TIMESTAMP	Marca de tiempo automática que registra el momento exacto en que se cargó la predicción.

6.2 Página de predicciones en el tablero

